기하학적 특징 추가를 통한 얼굴 감정 분석 개선 제안

지 도 교 수 한 희 일

한국외국어대학교

공과 대학 정보통신공학과

정 호 영
심 준 보

제출일 2023년 11월 17일

기하학적 특징 추가를 통한 얼굴 감정 분석 개선 제안

청구 및 승인서

기하학적 특징 추가를 통한 얼굴 감정 분석 개선 제안

소 속 : 공 과 대 학　　학 과 : 정보통신공학

학 번 : 201903322　　성 명 : 정 호 영
학 번 : 201802083　　성 명 : 심 준 보

이 논문을 제출하오니 승인하여 주십시오.

2023년 11월 17일

성 명 : 정 호 영 (인) 정호영
성 명 : 심 준 보 (인) 심준보

위 학생의 논문 제출을 승인함.

지 도 교 수 : 한 희 일 (인)

목차

1. 서론

2. 관련 연구

3. 배경 지식
   3.1) ASM 알고리즘을 통한 얼굴 이미지 랜드마크 추출
      3.1.1) 형상 모델 초기화
      3.1.2) 얼굴 정렬
      3.1.3) ASM 알고리즘 선택 여부
      3.1.4) ASM 프로파일 모델
   3.2) VGG 네트워크 소개
      3.2.1) VGG16
      3.2.2) VGG19
   3.3) Inception 네트워크 소개
      3.3.1) InceptionV1
      3.3.2) InceptionV2
      3.3.3) InceptionV3
   3.4) 모델 평가지표
      3.4.1) 분류 모델 성능 평가지표

4. 제안 알고리즘
      4.1) 랜드마크 특징 수 조절
      4.2) FACS 방법론 기반 특징점 추가
      4.3) CNN 네트워크와 MLP 네트워크 합치는 통합 네트워크 제안

5. 실험
   5.1) 데이터셋

5.2) 전처리
5.3) 데이터증강
5.4) MLP 네트워크 특성맵 크기 조절
5.5) FACS 방법론 기반 정보 추가
5.6) 실험 결과

6. 결론

7. 참고문헌

그림 목차

[그림3-1] ASM 알고리즘 학습 과정
[그림3-2] 초기 기준벡터와 N개의 벡터
[그림3-3] ASM을 통한 랜드마크 추출
[그림3-4] 3×3 합성곱 필터 3개 사용 후 피쳐맵 크기
[그림3-5] 7×7 합성곱 필터 사용 후 피쳐맵 크기
[그림3-6] 초기 인셉션 모듈
[그림3-7] 1×1 합성곱 필터를 사용한 인셉션 모듈
[그림3-8] Inception 모듈
[그림3-9] 재현율과 정밀도
[그림4-1] MLP 네트워크 구조
[그림4-2] 액션 유닛의 조합에 대응되는 랜드마크 간 거리정보 선정
[그림4-3] 제안 알고리즘 구조
[그림5-1] FER2013 클래스별 이미지
[그림5-2] 이미지에 대한 데이터 증강
[그림5-3] VGG 네트워크와 MLP 네트워크 통합
[그림5-4] Inception 네트워크와 MLP 네트워크 통합
[그림5-5] FACS 방법론 기반 정보 추가한 경우 알고리즘 정확도 비교
[그림5-6] FACS 방법론 기반 특징 추가 유무에 따른 정확도 비교
[그림5-7] VGG 네트워크 오차행렬 비교
[그림5-8] Inception 네트워크 오차행렬 비교

표 목차

[표3-1] VGG 네트워크 깊이 별 파라미터 수, 오차율
[표3-2] VGG16 구조
[표3-3] VGG19 구조
[표3-4] Inception 구조
[표3-5] 오차 행렬
[표4-1] VGG, Inception 분류기 피쳐맵 크기
[표4-2] FACS 액션 유닛
[표4-3] 액션유닛에 대응되는 랜드마크
[표5-1] FER2013 클래스 별 데이터 분포
[표5-2] FER2013 전처리 후 클래스 별 데이터 분포
[표5-3] MLP 결과 특성맵에 따른 정확도 비교
[표5-4] 제안 알고리즘 정확도 비교
[표5-5] VGG 네트워크 F1 점수 비교
[표5-6] Inception 네트워크 F1 점수 비교
[표5-7] FER2013 데이터셋에 대한 모델 정확도 비교

요약

얼굴 감정 분류(Facial Expression Recoginition)는 컴퓨터 비전과 인공지능의 발전에 따라 활발히 연구되고 있다. 기존의 얼굴 감정 분석 모델은 합성곱 신경망과 순환 신경망을 기반으로 하여, 훈련 데이터를 사용하여 얼굴 이미지와 해당 감정 사이의 관계를 학습한다. 그러나 이러한 모델은 미묘한 감정이나 조명, 각도, 배경 등의 외부 조건에 민감하게 반응하여 잘못된 감정 분류 결과가 나올 수 있다. 또한 다양한 환경 및 개체에서 일반화 능력이 저하되는 문제점을 보인다. 이에 본 논문은 위의 제약 사항을 극복하기 위해 ASM(Active Shape Model) 알고리즘과 FACS(Facial Action Coding System)를 기반으로 한 얼굴 특징점 결합 방법을 제안한다. 최종적으로 얼굴 특징점 기반의 다중 퍼셉트론과 합성곱 신경망을 결합한 투 스트림 네트워크를 구축하여 얼굴 이미지에 대한 감정을 분류하고자 한다. 이를 통해 다양한 인종, 연령, 성별과 같은 다양성을 고려하고 다양한 감정 상태를 식별하여 미묘한 차이를 구별하는 것을 목표로 하였다. 결과적으로 합성곱 단일 네트워크 모델에 랜드마크 기반 특징점을 추가함으로써 VGG는 1.29%, Inception 0.99%의 정확도가 향상됨을 확인할 수 있다. 이는 특징점 추가가 유의미한 정보임을 보인다. 추가적으로 모델의 성능을 개선하기 위해 데이터 전처리 기술 등 추가적인 연구 및 방법론의 탐구가 필요하다.

1. 서론

얼굴 감정 분석은 감정을 인식하고 해석하는 중요한 분야로, 컴퓨터 비전과 기계학습 기술의 발전으로 인해 많은 주목을 받고 있다. 사람들은 얼굴 표정을 통해 기쁨, 분노, 슬픔, 놀라움과 같은 다양한 감정을 표현하며, 이러한 정보를 기반으로 상황을 이해하고 상호 작용한다. 얼굴 감정 분석 기술은 환자의 정서 상태를 파악하여 치료 방향을 결정하는 정신 건강 평가와 학습자의 흥미와 집중도를 측정하여 개인 맞춤형 교육을 제공하는 정서 지능 교육뿐만 아니라, 마케팅 및 광고 분야, 고객 서비스 자동화 등 다양한 분야에서 활용되고 있다.

얼굴 감정 분석 기술은 환자의 얼굴 표정 데이터를 분석하여 우울증,불안,스트레스와 같은 정신 건강 문제를 진단하고 적절한 조치를 취하는데 도움을 준다.[1] 얼굴 감정 분석은 인간과 컴퓨터의 상호작용 및 감정 인식 로봇 분야에서도 사용되는데[2], 이는 사용자의 감정을 감지하고 이해하여 보다 개인화된 서비스를 제공해 준다. 뿐만 아니라, 소비자의 얼굴 표정을 분석하고 감정 반응을 추적하여 마케팅 및 광고 분야에서도 중요한 역할을 하며[3], 심리학 연구[4], 정서 지능 교육 등 다양한 분야에서 활용되고 있다.

그러나 기존의 얼굴 감정 분석 모델은 모호한 표정, 조명, 얼굴 각도 등 다양한 외부요인들로 인해 정확성을 유지하는 것이 어려운 경우가 있다. 또한, 특정 환경과 개체에 대해서만 효과적으로 작동하고 다양한 환경 및 개체에 대한 감정 분석에서 일반화 능력이 저하될 수 있다. 예를 들어, 모델이 특정 인종, 연령, 또는 문화적 배경에 대해 훈련이 되었다면, 다른 인종, 연령 및 문화적 배경의 개체에 대한 감정 분석에서 제한 사항이 발생할 수 있다. 결론적으로 기존의 얼굴 감정 분석 모델은 범용성이 제한되며, 다양한 환경과 다양한 인구에 대한 감정 분석의 정확성이 저하된다는 문제점이 있다. 따라서 모델의 성능을 향상시키고 일반화 능력을 확장하기 위해 다양한 데이터와 다양한 조건을 고려해야 한다.

얼굴 감정 분석 분야는 현재, 딥러닝 기술의 발전과 함께 중대한 변화를 겪고 있다. 과거에는 얼굴 이미지에서 감정을 판별하기 위해 전통적인 특징 기반 분류 방법이 널리 사용되었다. 이러한 방법에는 Histogram of Oriented Gradients (HOG), Local Binary Pattern (LBP), 그리고 주성분 분석(PCA)을 포함한 여러 기계학습 기반의 알고리즘이 있다. HOG는 그래디언트 방향의 분포를 활용하여 얼굴 패턴을 추출하는 방식으로 사용되며, LBP는 텍스처 패턴을 인코딩하기 위해 이진 패턴을 고려한다. Eigenfaces는 PCA를 통해 얼굴 이미지를 특성화하여 감정을 분석한다. 그러나 이러한 방법들은 지역적인 정보에 초점을 맞추어, 1차원 벡터로 변환하는 과정에서 공간적인 정보를 손실하기에 이미지 내에서 픽셀 간의 상관관

계를 고려하지 못하는 한계가 있다. 또한, 낮은 수준의 특징을 추출하므로 고수준의 추상적인 패턴을 효과적으로 인식하지 못한다는 문제점이 있다.

이러한 문제점을 해결하기 위해 최근에는 합성곱 신경망과 순환 신경망과 같은 딥러닝 기술이 사용되고 있다. 합성곱 신경망을 활용한 얼굴 감정 분석은 저수준의 특징에서 고수준의 추상적인 특징을 추출한다. 또한 합성곱 필터를 통해 주변 픽셀과의 연관관계를 유지하며 학습하기에 얼굴 이미지의 공간적 특징을 고려할 수 있다. 그러나, 합성곱 신경망 모델은 특정 데이터셋에 과도하게 최적화되기 쉬워 새로운 환경이나 다른 문화적 배경에서 일반화하기 어려운 한계가 발생할 수 있다. 한편, 얼굴 랜드마크를 활용한 감정 분석은 얼굴의 세부적인 특징을 포착하여 눈, 코, 입, 눈썹과 같은 부분을 정확하게 식별하고, 상대적으로 데이터양에 크게 의존하지 않아 새로운 데이터나 환경에서도 강력한 성능을 유지한다. 그러나, 랜드마크 추출 과정의 어려움과 민감성을 갖고 있다.

본 논문은 이러한 제약 사항을 해결하기 위해 ASM 알고리즘을 활용하여 기본적인 얼굴 특징점을 추출하고, 이에 더해 FACS를 기반으로 의미 있는 특징점을 추가로 선정한다. 최종적으로 특징점을 활용하여 완전 연결 기반의 네트워크를 개발하고, 이미지 데이터를 입력으로 사용하기 위해 합성곱 네트워크를 통합한다. 본 제안 방식은 감정 분석 모델의 정확도와 다양한 환경에서의 일반화 능력을 향상시킬 것으로 기대된다.

본 논문의 구조는 다음과 같다. 2장에서는 관련 연구를 살펴보고 얼굴 감정 분석 분야에서의 선행 연구 및 한계점을 요약한다. 3장에서는 논문의 핵심 개념을 이해하기 위한 배경 지식으로 ASM, VGG, INCEPTION과 모델 성능 평가지표를 다루며, 4장에서는 본 연구에서 제안하는 통합 네트워크를 소개한다. 5장에서는 실험에 대한 전반적인 구성으로 데이터셋, 전처리, 데이터 증강, MLP 네트워크 특성맵 크기 조절, FACS 방법론 기반 정보추가, 실험 결과순으로 설명한다. 6장은 연구 결과를 바탕으로 한계와 향후 연구 방향을 제안하며 마무리한다.

2. 관련 연구

얼굴 감정 분석은 컴퓨터 비전 및 인공지능 분야에서 중요한 연구 주제 중 하나로 각종 응용 프로그램, 특히 감정 기반 인터페이스 및 감정 인식 시스템에 폭넓게 활용되고 있다. Emily Davis et al[5]은 얼굴 감정 인식에 대한 조사를 제공하며, 감정 분석 분야에서의 과거부터 최신까지의 동향과 어려움을 제시한다.

과거에는 HOG(Histogram of Oriented Gradients), LBP(Local Binary Patterns), PCA(Principal Component Analysis)와 같은 전통적인 특징 추출 방법이 널리 사용되었다. HOG는 얼굴 이미지에서 특정 방향으로의 경사 정보를 추출하는 방법이다. 예를 들어, 행복한 얼굴은 눈이 가로로 퍼져 있으므로 해당 방향의 경사 정보를 활용하여 표정을 인식한다. Al-Talabani et al.[6]는 HOG를 통한 특징 추출에 시퀀스 데이터를 다루는데 효과적인 모델인 HMM(Hidden Markov Models)를 결합하여 얼굴 표정 인식에서 효과적인 성능을 보이는 방법을 제안했다. 이는 시간에 따른 변화를 갖는 얼굴 표정에서 동적 특성을 모델링하는 HMM이 효과적임을 말한다.

LBP는 얼굴 이미지를 작은 블록으로 나누고 각 블록에서 텍스처 패턴을 추출하는 방법이다. 슬픈 얼굴과 행복한 얼굴의 눈 주변 텍스처 패턴이 다르므로 LBP는 이를 인식하여 얼굴 감정인식에 사용한다. Timo Ahonen et al.[7]은 LBP를 사용하여 얼굴 표정을 인식하는 방법을 다루며, LBP의 장단점에 대해 시사한다. 현실에서는, 얼굴은 다양한 각도에서 관찰되어 회전 불변성을 갖지 않으면 얼굴의 정확한 정렬이나 방향 정보를 필요로 한다. 회전 불변성을 갖는 시스템인 LBP는 회전시킬 필요없이 다양한 각도에서 얼굴 표정을 분석하는데 효과적이다. 이는 다양한 각도와 방향에서의 얼굴 이미지를 포함한 훈련데이터 구성이 가능하기 때문에 다양성을 처리할 수 있는 강건한 모델을 구축할 수 있다. 하지만, LBP는 입력 이미지의 크기에 민감하여 크기가 다른 객체에 대해 특징을 추출하거나 패턴을 분석하는데 어려움을 겪는다.

주성분 분석(PCA)은 얼굴 이미지의 차원을 축소하고 주요 특징을 추출하는데 활용되었다. 얼굴 이미지의 주성분을 찾아내어 각 얼굴 표정을 주성분의 선형 조합으로 표현하고 이를 기반으로 감정 분류를 수행한다. Kulkarni et al.[8]는 다양한 연구에서 PCA를 얼굴 표정 인식에 적용한 방법과 성능을 검토하며, PCA의 활용과 한계를 말한다. PCA를 활용한 얼굴 감정 분석은 주요 정보를 추출하고 노이즈를 제거함으로써 모델의 일반화 능력을 향상시키며, 다양한 환경과 조건에서 얼굴 표정을 인식하는데 도움이 된다. 하지만, PCA는 회전 및 크기 변화에 민감하여 이미지 정렬을 필요로 한다. 또한, 얼굴 표정은 비선형적이고 복잡한 패턴으로

나타나기 때문에 선형 특징을 추출하는 PCA 단독으로는 얼굴 표정의 다양성을 충분히 표현하기 어렵다.

이러한 전통적인 방법은 초기 얼굴 감정 분석 연구에 중요한 역할을 했으며, 감정 표현의 기본 특징을 추출하고 분석하는데 사용되었다. 그러나 얼굴의 복잡한 특징을 충분히 고려하지 못하고 이미지 내에서 지역 정보와 픽셀 간의 상관관계를 고려하지 못하는 한계가 있다.

따라서, 이러한 전통적인 방법은 합성곱 신경망 및 순환 신경망과 같은 딥러닝 알고리즘의 등장으로 대체되거나 보완되었다. 또한, 기존 모델에서 발생할 수 있는 특정 환경 또는 조건에서의 감정 분석 일반화 성능 저하 문제를 해결하기 위해 다양한 정보 소스의 결합이 필요하여 다중 모달 접근법이 중요성을 갖게 되었다. 이는 기존의 얼굴 감정 분야에서는 주로 정적인 이미지나 동영상 프레임에서 얼굴 특징을 추출하여 감정을 인식하는데 그쳐, 음성, 눈 깜박임 등과 같은 다양한 데이터 소스의 통합 부재와 감정 표현의 복잡성 문제를 해결하기 어렵다는 어려움을 말한다.

Brais Martínez et al.[9]은 감정을 인식하기 위해 음성, 영상, 텍스트등 다양한 데이터를 통합하는 것의 중요성을 강조한다. 이를 다중 모달 접근법이라 하며, 다중 모달 접근법은 한 가지 모달리티만 사용하는 방법보다 다양한 모달리티를 사용함으로서 환경이나 조건의 변화에 더 강인한 모델을 구축할 수 있다. 예를 들어, 시각적 정보만 사용하는 기존의 모델은 조명 조건이나 얼굴 각도의 변화에 취약할 수 있지만, 음성 정보나 텍스트 정보를 함께 사용하면 이러한 문제를 극복할 수 있다. 하지만, 다중 모달 데이터의 수집 및 전처리는 단일 모달 데이터보다 더 복잡한 과정을 필요로 한다. 각 모달리티의 데이터는 동일한 시간 기준에 따라 정확하게 동기화 되어야하며 이것은 어떤 음성 데이터나 텍스트 데이터가 특정 이미지 데이터와 정확히 일치하는지 확인해야함을 의미한다. 또한, 서로 다른 형식과 구조를 가지기에 통일된 형식으로 변환해야하며, 다중 모달 데이터는 노이즈와 같은 불필요한 정보를 포함할 가능성이 높다.

다중 모달 데이터의 복잡성과 노이즈에 대응하기 위해, 감정 분석을 향상시키기 위한 접근법이 연구되었다. Sarah Brown[10]는 감정표현의 복잡성을 고려하여 정확한 감정 분석을 수행하는 방법으로 불필요한 정보를 제외한 눈, 코, 입과 같은 얼굴의 주요 랜드마크를 검출하는 기술의 중요성을 강조한다. 위 논문은 감정표현의 핵심 지점을 식별한다는 것과 개인별 차이를 고려하기 위하여 판단할 수 있는 근거로 얼굴 랜드마크를 제시하였고 정확한 랜드마크 검출의 중요하다고 말한다. 이에 따라 다양한 랜드마크 검출 알고리즘이 제시되었고, Ren S et al.[11] 바이너

리 정보를 활용하여 다양한 기하학적 특징 포인트를 추출하는 방식을 제안하였다. 그러나, 랜드마크 검출의 정확도 및 실시간 처리의 한계가 존재했다. Jennifer White[12]는 랜드마크 검출의 정확도를 개선하고 빠른 처리를 위한 최적화된 알고리즘을 제안한다. 랜드마크 검출의 정확도를 위해 이미지에서 변화에 강인함을 찾아내기 위해 지역 정보를 중요하게 생각하였고, 지역 정보 특징 추출의 중요성을 강조한다. 이러한 특징은 회전, 크기 변화, 일부 왜곡 등에 대해 강건한 특성을 가지며, 객체 인식 및 패턴 매칭과 같은 작업에 쓰인다. 추출된 지역 특징을 사용하여 감정 분류 모델을 훈련을 시켰으며, 머신러닝 기반 서포트 벡터 머신, 랜덤 포레스트를 사용하여 얼굴 이미지에 대한 감정을 분류한다.

Fabian Caba Heilbron[13]은 전통적인 머신 러닝 기반얼굴 감정 분석 방법은 이미지 속 상관관계를 반영하지 않는 한계점를 극복하기 위해 CNN을 활용하여 얼굴 이미지에서 감정을 분석하는 방법을 제안한다. 이 방법은 CNN을 이용하여 얼굴 이미지의 고수준 특징을 추출하고, 주변 환경 정보를 종합하여 감정을 더 정확하게 분류한다.

Christopher Pramerdorfer[14]가 제안한 Inception 모델 또한 높은 정확도를 보였다. 위 모델은 VGG 네트워크 구조와 비슷하게 일관된 구조를 갖추고자 하였으며 초기 단계에서는 strided 컨볼루션 또는 풀링을 사용하지 않아 기존 이미지 정보의 손실을 최소화하며 성능을 높이고자 하였다.

이렇게 합성곱 신경망 기반 네트워크는 이미지 기반의 감정 분석에 효과적으로 적용되고 있으며 Brais Martinez[15]는 데이터의 불균형 문제를 인식하고 이를 해결하기 위해 VGGNet 신경망에 회전, 반전과 같은 데이터 증강 기법을 적용하였으며, 크로스 엔트로피 손실 함수를 활용하여 높은 정확도와 성능을 증명했다. 또한, S. Vignesh et al.[16] 제안하는 합성곱 신경망 기반의 VGG 네트워크는 얼굴 표정 인식 작업에 효과적으로 중요한 개선 사항을 도입했다. 이 네트워크의 핵심 아이디어는 VGG 아키텍처의 중간에 U-Net 분할 레이어를 추가하여 네트워크가 얼굴 이미지로부터 중요한 정보를 추출하고 중복 정보를 효과적으로 관리한다. U-Net은 이미지 분할 작업에서 효과적으로 사용되는 딥러닝 아키텍처 중 하나로, 입력 이미지에서 원하는 객체 또는 특징을 식별하고 분할하는 데 도움을 준다. 따라서, U-Net 분할 레이어를 VGG 아키텍처 중간에 삽입함으로써, 얼굴 표정 인식 작업에 중요한 특징과 정보를 강조하고 효과적으로 관리할 수 있게 한다.

Yaniv Taigman[17]는 CNN 기반의 DeepFace 모델을 제시한다. 이 모델은 얼굴을 3D 모델로 변환하여 얼굴 특징을 추출하고, 얼굴 감정 분석과 얼굴 인식 작업을 수행한다. 이는 대규모 데이터셋을 기반으로 학습하여 다양한 얼굴 표현을 인

식할 수 있으며 뛰어난 얼굴 인식 및 감정 분석 성능을 보인다. 다만, 다양성 있는 데이터 셋에 대한 성능 평가가 부족하며, 특히 특정 인종, 성별 또는 나이 그룹에 대한 일반화 성능 평가가 부족하다는 한계점이 있다.

Michael Wand et al.[18]는 다양한 입력을 활용하여 감정 인식에 RNN을 적용하는 방법을 다룬다. RNN은 시계열 데이터를 처리하는데 효과적이며, 각 데이터 포인트 간의 시간적 관계를 고려할 수 있다. 이는 감정 인식에서 동적의 표현 및 변화를 인식하는데 유용하다. 또한 영상, 음성과 같은 다양한 입력 정보를 융합하여 감정 분석에 활용할 수 있다. 하지만, RNN은 데이터의 시퀀스적 특성을 고려하므로 과적합 문제에 민감할 수 있으며, 이를 해결하기 위해 정규화 및 데이터 증강 기법이 필요하다.

Xuankai Chang et al[19]은 얼굴 표정을 인식을 위해 CNN과 RNN을 결합한 방식에 대해 다룬다. CNN을 사용하여 얼굴 이미지에서 중요한 특징을 추출하고, 추출한 특징 벡터를 RNN에 입력하여 순서 정보를 고려한 감정 분석을 수행한다. 그러나, 이 또한 과적합 문제가 발생할 수 있어 일반화 성능이 저하된다.

본 논문은 위에서 언급한 다양한 데이터, 다양한 환경에서의 일반화 능력을 향상하고자, 합성곱 네트워크에 얼굴 특징점을 결합하여 이미지 내에서의 부분 간의 상관관계 정보와 보편적인 특성을 추출하고자 한다. 이를 통해 얼굴 감정 분석 모델의 성능을 높이고자 한다.

3. 배경지식

3.1 ASM 알고리즘을 통한 얼굴 랜드마크 추출

물체의 특징을 추출하는 방법으로 HOG[20](Histogram of Oriented Gradient), ASM[21](Active Shape Model), AAM[22](Active Appearance Model)과 같은 방법이 존재한다. HOG는 이미지를 일정크기의 셀로 분할하고 방향에 대한 히스토그램을 연결한 벡터로 기하학적 정보를 유지한다는 장점이 있다. 하지만 각 블록 단위의 대한 정보만 지니기에 물체의 회전이나 내부 형태 변화가 심할 경우 특징점 검출에 어려움이 존재한다. 이에 반해 ASM은 물체의 전체에 통계 정보를 활용하여 새로운 이미지에 대해 특징을 추출하여 이러한 문제들을 해결한다. AAM은 ASM에 텍스처 정보를 활용한 모델로 ASM의 성능을 개선하기 위해 개발되었다. 하지만 AAM은 기존의 모델의 특징점과 추출한 특징점 사이의 거리인 점대점[23] 오류가 ASM보다 크다는 단점이 존재한다. 본 논문에서는 정확한 특징점 위치 탐지를 통한 특징점 간 거리 정보를 특징으로 사용하기에 ASM을 채택한다.

ASM은 이미지에서 원하는 형태를 구하기 위해 데이터의 반복적인 변형을 통해 특징점을 추출하는 통계적 형태모델이다. ASM의 형태모델을 구현하기 위해 기준 형태 모델을 정렬해야 하며 이를 위해 충분한 양의 훈련 이미지 데이터셋이 필요하다. 동일한 특징점의 통계적 특성을 통해 기준 형태모델을 구할 수 있다. 기준 형태 모델을 구하기 위해 형태 모델 정렬, 통계 정보 추출의 과정을 반복한다.[21,24]

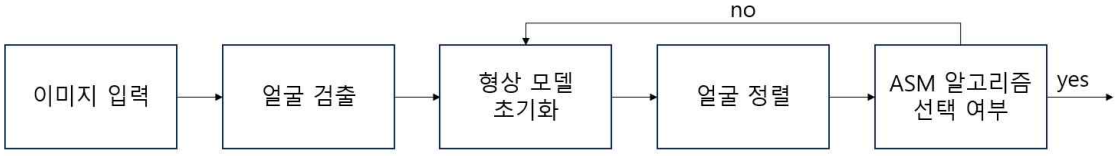

[그림3-1] ASM 알고리즘 학습 과정

3.1.1 형상 모델 초기화

모델을 구성하기 위해서는 훈련 이미지 데이터셋에 대하여 얼굴을 검출한 뒤, 윤곽선마다 점들을 라벨링 해주어야 하며, 얼굴 이미지의 경우 각 점을 랜드마크라고 한다. 아래 수식에서 k는 랜드마크의 개수를 의미한다.

$$x = (x_{i1}, y_{i1}, x_{i2}, y_{i2} \cdots, x_{ik}, y_{ik})^T \tag{1}$$

처음으로 모델을 형성할때는 N개의 이미지중에서 1번째 이미지를 기준 형태백터 x_i로 설정하고 초기 기준 형태벡터는 다음과 같이 표현된다.

$$x_i = (x_{11}, y_{11}, x_{12}, y_{12} \cdots x_{1k}, y_{1k})^T \tag{2}$$

3.1.2 얼굴 정렬

두 개의 형태 벡터 x_i, x_j가 존재할 때 기준 형태 벡터를 x_i라고 하면, x_j를 x_i에 맞추기 위해서 Cootes[21]는 닮음변환을 이용하여 정합하고, 최소제곱법을 사용하여 거리를 최소화하는 방법을 채택하였다. 닮음변환이란 회전, 크기변환, 평행이동을 이용하여 x_j를 x_i에 일치시키는데, 회전과 크기변환은 일종의 매핑 함수이며, 평행 이동은 가중치라고 생각할 수 있다. 회전 θ, 크기변환 s, 평행이동을 t라고 할 때 x_j의 닮음변환 형태를 $x_j^{'}$ 를 다음과 같이 나타낼 수 있다.

$$\begin{bmatrix} x_{jk}^{'} \\ y_{jk}^{'} \\ 1 \end{bmatrix} = \begin{bmatrix} s_j\cos\theta_j & -s_j\sin\theta_j & t_x \\ s_j\sin\theta_j & s_j\cos\theta_j & t_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_{jk} \\ y_{jk} \\ 1 \end{bmatrix} \tag{3}$$

변환된 형태 $x_j^{'}$와 x_i의 최소제곱법을 통한 오차를 구하면 다음과 같다.

$$\begin{aligned} E &= \sum_{n=1}^{k} (x_{\in} - x_{jn})^2 \\ &= \| x_i - x_j \|^2 \\ &= (x_i - x_j)^T (x_i - x_j) \\ &\fallingdotseq (x_i - x_j)^T W (x_i - x_j) \end{aligned} \tag{4}$$

여기서 W는 각 랜드마크의 가중치를 나타내는 대각행렬이며, 필요에 따라 가중

치를 별도로 제공하며 대부분의 방식에서 기본적으로 단위행렬을 할당한다.

3.1.3 ASM 알고리즘 선택 여부

훈련데이터셋에 대하여 랜드마크를 훈련데이터셋의 개수가 N개라고 할 때, 2차원 공간상에 k개의 랜드마크가 N개의 형태벡터로 구해진다. N개의 형태 벡터를 통하여 $2k \times 1$ 평균 형태 벡터를 구할 수 있다.

$$\overline{x} = \frac{1}{N}\sum_{i=1}^{N} x_i' \tag{5}$$

[그림3-2]은 초기기준형태 벡터와 30개의 형태벡터를 이미지상으로 나타낸 것을 보여준다.

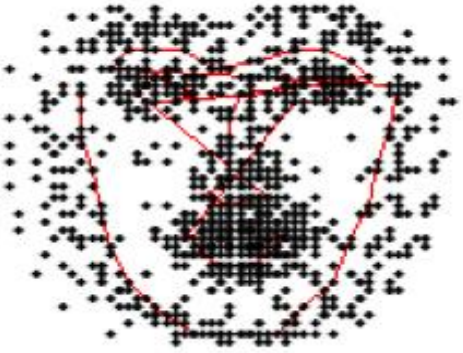

[그림3-2] 초기 기준벡터와 N개의 벡터

N개의 정렬된 형태 벡터와 평균 형태벡터를 이용하여 PCA를 적용하고, 계산을 통해 통계정보를 추출한다. 통계정보를 추출하기 위해 $2k \times 2k$ 공분산 행렬을 구한다.

$$C = \frac{1}{N}\sum_{i=1}^{N}(x_i' - \overline{x})^T(x_i' - \overline{x}) \tag{6}$$

데이터의 차원을 축소하기 위해 주성분 분석을 사용한다. 이 행렬에서 고유값과 고유벡터를 다음과 같이 구한다.

$$C\vec{e} = \lambda\vec{e} \tag{7}$$

$\vec{e}_k$는 크기가 1로 정규화되어 있으며 λ는 내림차순 되어있다 가정하면 λ_k는 k번

째로 큰 고유값이고 $\vec{e}_k$는 λ_k에 대응되는 정규화된 고유벡터이다. 공분산 행렬의 고유값은 형태 공간의 분산과 동일하며 이는 λ_k에 대응되는 e_k는 형태 공간의 특징점에서 가장 가변적인 특성을 나타낸다. PCA는 고차원 데이터에서 패턴을 찾는 알고리즘 중 하나이며, 데이터가 포함하는 정보를 선택하여 모델 학습 성능을 향상시킨다. 주성분 분석은 데이터의 의미 있는 축을 찾는데 이 축을 주성분이라고 하며, 초기에는 데이터의 차원 수만큼의 주성분이 존재한다. 이러한 주성분중에서 우선순위를 구하여 차원을 축소하는 알고리즘이다. 데이터셋 X를 단위벡터 $\vec{e}$에 정사영 시킨 결과를 $X\vec{e}$라고 할 때 분산은 다음과 같이 표현된다.

$$\begin{aligned} Var(X\vec{e}) &= \frac{1}{m-1}\sum_{i=1}^{m}(X\vec{e} - E(X\vec{e}))^2 \\ &= \frac{1}{m-1}\sum_{i=1}^{m}(X\vec{e} - E(X)E(\vec{e}))^2 \\ &= \frac{1}{m-1}\sum_{i=1}^{m}(X\vec{e})^2\ (\because E(X)=0) \\ &= \frac{1}{m-1}(X\vec{e})^T(X\vec{e}) \\ &= \frac{1}{m-1}\vec{e}^T X^T X\vec{e} \\ &= \vec{e}^T \frac{X^T X}{m-1}\vec{e} \\ &= \vec{e}^T C\vec{e}\ (\because C = \frac{X^T X}{m-1}) \end{aligned} \tag{8}$$

정사영시킨 $X\vec{e}$는 X의 공분산 행렬을 포함하고 있으며 공분산 행렬을 고유값 분해하면 다음과 같이 표현된다.

$$\begin{aligned} C\vec{e} &= \lambda\vec{e} \\ \vec{e}^T C\vec{e} &= \vec{e}^T\lambda\vec{e} \\ &= \lambda\vec{e}^T\vec{e} \\ &= \lambda \end{aligned} \tag{9}$$

이를 통해 공분산 행렬의 고유값은 데이터셋 X를 단위벡터 $\vec{e}$에 사영시켰을 때의 분산과 같으며, 고유값의 대응되는 고유벡터가 단위벡터이다.

$$\therefore Var(X\vec{e}) = \vec{e}^T C\vec{e} = \lambda \tag{10}$$

주성분 분석을 통해 특징점을 잘 표현하는 고유벡터 t개를 선택한다. 대부분의 객체의 경우 고유값 중 일부가 큰 값을 가지고 나머지는 작은 값을 가지기에 이

는 정보는 일부 손실하지만 계산량을 크게 줄일 수 있어 효과적이다. 또한 특이값 분해를 이용하여 기존의 모양과 근사한 형태를 대략적으로 복구할 수 있다.

$$x_{appr} = \bar{x} + \Phi b \tag{11}$$

이 식에서 Φ는 t개의 고유벡터이며, b는 고유벡터의 비례상수로 구성되어 있다. b_k의 분산은 λ_k와 일치하고, 훈련 데이터셋이 충분히 많아 가우시안 분포에 근사하다고 할 때 형태 벡터의 99%의 정보가 $\pm 3\sigma$ 이내 존재하기에 b_k의 범위를 다음과 같이 나타낼 수 있다.

$$-3\sqrt{\lambda_k} \le b_k \le +3\sqrt{\lambda_k} \tag{12}$$

b_k가 식12 범위안에 수렴함으로써 대부분의 얼굴 형태에 대한 변화량을 포함할 것으로 파악된다.

3.1.4 ASM 프로파일 모델

이미지마다 형태벡터를 구성하는 각 랜드마크 주위 특성정보는 다르기 때문에 랜드마크를 효과적으로 검출하기 위해 특성정보를 나타내는 특징벡터 모델이 필요하다. Cootes[20]는 이러한 특성정보를 추출하기 위해 프로파일을 1-D 특징 벡터로 이용하였다. 이 기술은 전통적인 ASM으로 불리우며 그 이후 대부분의 논문은 2-D 프로파일 모델을 포함한다.

1-D 프로파일 모델은 이미지에 대하여 각 랜드마크의 수직 벡터 $\vec{g}$를 추출한다. 벡터 $\vec{g}$를 정규화 한 벡터를 g라고 할 때, N개의 훈련이미지에 대하여 평균 프로파일 벡터 $\bar{g}$와 그에 대한 공분산행렬 C_g는 다음과 같이 표현된다.

$$\bar{g} = \frac{1}{N}\sum_{i=1}^{N} g_i \tag{13}$$

$$C_g = \frac{1}{N-1}\sum_{i=1}^{N}(g_i - \bar{g})^T(g_i - \bar{g}) \tag{14}$$

본 논문에서는 형태 벡터를 구성하는 랜드마크를 68개를 선정하기에 각 랜드마크마다 $\bar{g}$프로파일 벡터와 C_g 공분산행렬이 필요하다. 이를 통해 새로운 이미지에

대하여 랜드마크를 검출할 수 있다. 이미지에 대한 g' 프로파일 벡터와 평균 프로파일 벡터 $\bar{g}$간의 마할라노비스 거리를 반복을 통해 최소화하며 랜드마크를 수렴시킨다. 각 단계마다 마할라노비스 거리를 사용하며 거리의 최소값을 갖는 프로파일 g'의 중심점을 인식하게 된다.

$$Mahalanobis\,Distance = (g' - \bar{g})^T C_g^{-1} (g' - \bar{g}) \tag{15}$$

[그림3-3]은 이미지에 대하여 ASM을 이용하여 랜드마크 검출이 완료된 형태 벡터들을 보여준다.

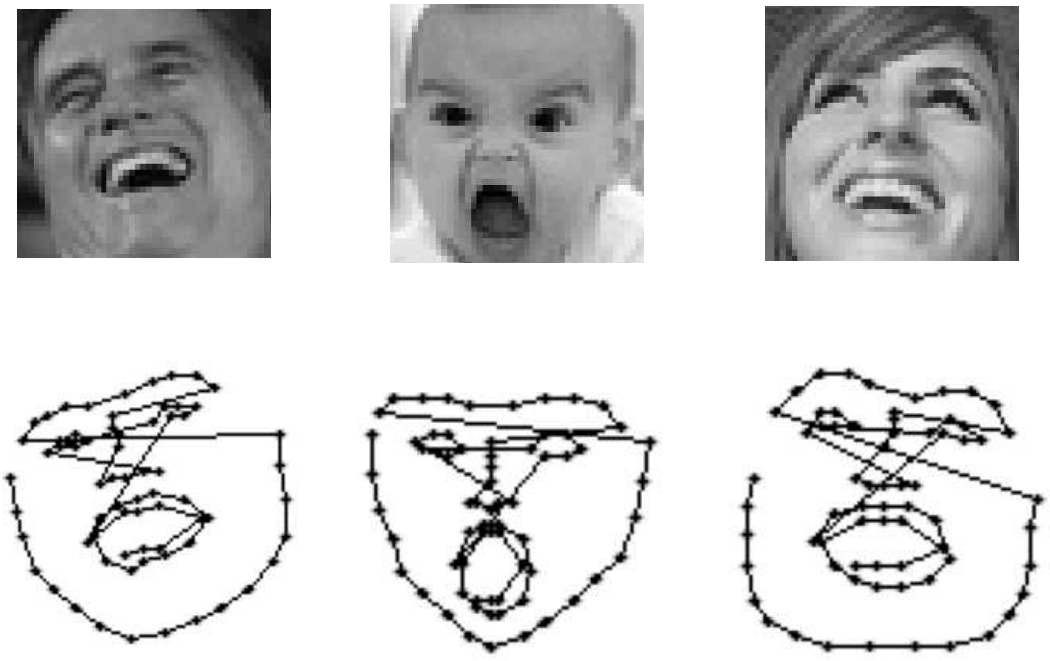

[그림3-3] ASM을 통한 랜드마크 추출

3.2 VGG 네트워크

CNN 네트워크는 2012년 ImageNet 대용량 이미지 인식 대회(ILSVRC)에서 우승한 이후 이미지 분류에 핵심적인 아키텍처 모델로 자리 잡았다. CNN 기반 네트워크 모델들을 통해 얼굴 감정 분류하는 방식에 연구가 활발히 진행되고 있으며 CNN 아키텍처를 기반으로 한 모델이 다수 등장하였으며, 세계 이미지 분류대회를 통해 AlexNet, Inception, VGG과 같은 다양한 모델이 연구되고 있다.

VGGNet[25]은 2014년 ILSVRC에서 준우승한 CNN 모델이다. 모델의 깊이의 따른 성능을 체크하고자 컨볼루션 연산 체크에 따라 [표3-1]와 같이 6개의 구조로 나누어 비교를 통해 모델의 깊이가 깊어질수록 객체 탐지 에러가 감소한다는 것을 확인하였다.

[표3-1] VGG 네트워크 깊이 별 파라미터 수, 오차율

합성곱 네트워크	층의 수	파라미터 수(m)	검증 오차율
A	11	133	10.4%
A-LRN	11	133	10.5%
B	13	133	9.9%
C	16	134	9.4%
D	16	138	8.8%
E	19	144	9.0%

VGGNet은 3×3 필터를 이용하여 층을 깊게 설계할 수 있었고, 이는 이미지 분류에서 좋은 성능을 보인다. VGG 네트워크의 대표적인 모델 VGG16는 [표3-2]와 같이 13개의 합성곱층과 3개의 완전 연결층으로 이루어지며 모든 합성곱은 3×3 필터를 사용한다. 또한 연산 시 스트라이드와 패딩은 1로 설정하고 활성함수로 Relu를 사용하며, 맥스풀링을 이용하여 피쳐맵의 크기를 조절한다.

[표3-2] VGG16 구조

	층 구성	**피쳐맵 크기**
입력 층	RGB 이미지	(224, 224, 3)
층 1	합성곱 계층 - 64개의 필터	(224, 224, 64)
층 2	합성곱 계층 - 64개의 필터	(224, 224, 64)
풀링 층 1	맥스 풀링	(112, 112, 64)
층 3	합성곱 계층 - 128개의 필터	(112, 112, 128)
층 4	합성곱 계층 - 128개의 필터	(112, 112, 128)
풀링 층 2	맥스 풀링	(56, 56, 128)

층 5	합성곱 계층 - 256개의 필터	(56, 56, 256)
층 6	합성곱 계층 - 256개의 필터	(56, 56, 256)
층 7	합성곱 계층 - 256개의 필터	(56, 56, 256)
풀링 층 3	맥스 풀링	(28, 28, 256)
층 8	합성곱 계층 - 512개의 필터	(28, 28, 512)
층 9	합성곱 계층 - 512개의 필터	(28, 28, 512)
층 10	합성곱 계층 - 512개의 필터	(28, 28, 512)
풀링 층 4	맥스 풀링	(14, 14, 512)
층 11	합성곱 계층 - 512개의 필터	(14, 14, 512)
층 12	합성곱 계층 - 512개의 필터	(14, 14, 512)
층 13	합성곱 계층 - 512개의 필터	(14, 14, 512)
풀링 층 5	맥스 풀링	(7, 7, 512)
플래튼	플래튼	(25088,)
층 14	완전연결층 - 4096개의 뉴런	(4096,)
층 15	완전연결층 - 4096개의 뉴런	(4096,)
층 16	완전연결층 - 1000개의 뉴런	(1000,)
소프트맥스	소프트맥스	(분류하고자하는 클래스 수,)

3.2.1 VGG16

VGGNet은 모든 컨볼루션 레이어에서 3×3 필터를 사용하여 AlexNet이 가진 8개의 층보다 2배 높은 깊은 신경망을 구축하였음에도 성공적으로 학습하였다. 필터 크기를 축소시킴으로서 학습 파라미터 수 감소와 모델 분류 비선형성을 증가시킬 수 있다는 이점을 가지고 있다. 7×7의 커널은 3×3 커널 3개로 대체 할 수 있다. 채널의 개수를 C, stride는 1, padding은 same을 사용하면 [그림3-4], [그림3-5]와 식 16과 같이 같은 피쳐맵이 결과로 나오는 것을 알 수 있다. 학습할 파라미터의 수는 $(7C)^2 = 49C^2$이 더 작은 커널로 분할 하였을 시 $3 \times (3C)^2 = 27C^2$으로 모델을 깊게 구축하여도 학습해야 할 파라미터 수를 크게 줄임을 알 수 있다. 또한 적용할 필터를 여러 개의 작은 필터로 분해하면서 더 많은 비선형 함수가 적용되기에 이는 모델의 비선형성이 증가하여 특징 식별성 증가로 이어지게 된다.

$$W_{out} = \frac{W_{\text{in}} - F + 2P}{S} + 1$$

$$H_{out} = \frac{H_{\text{in}} - F + 2P}{S} + 1 \qquad (16)$$

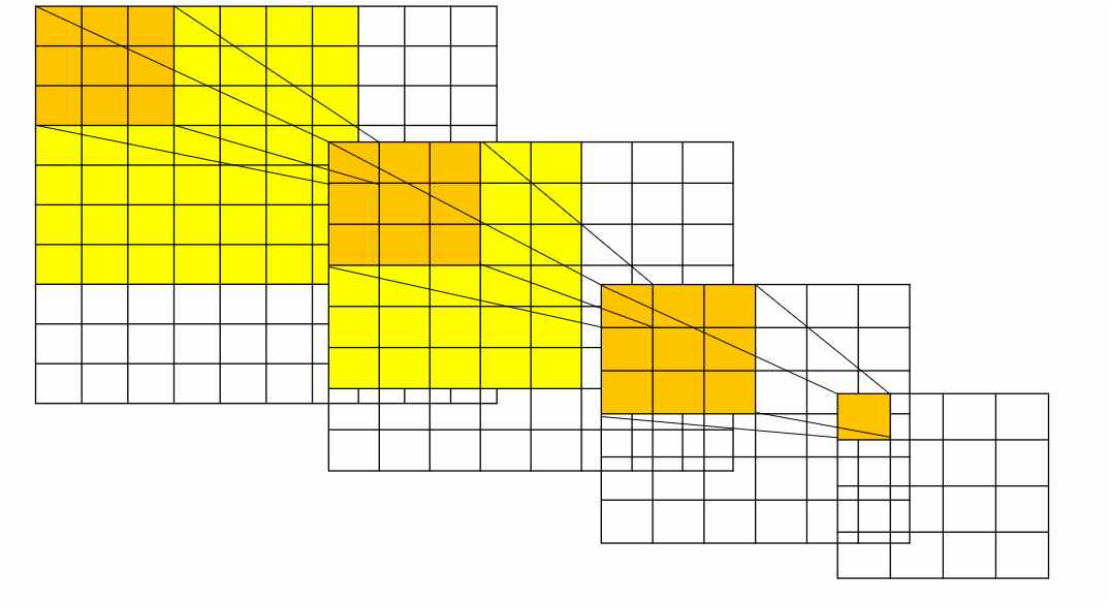

[그림3-4] 3×3 합성곱 필터 3개 사용 후 피쳐맵 크기

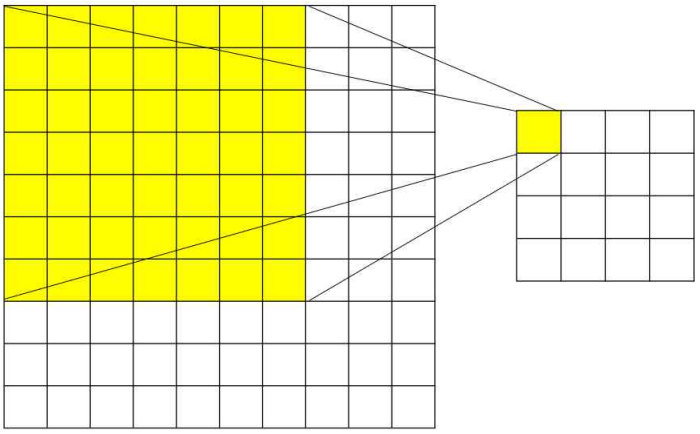

[그림3-5] 7×7 합성곱 필터 사용 후 피쳐맵 크기

모델의 깊이를 깊게 설계하였을 때 여러 층을 거쳐 엣지정보에서 추상적인 특징까지 더 많은 특징을 추출할 수 있다는 장점이 존재하지만, 모델이 학습데이터에 과적합되며, 학습 과정 중 그레디언트 소실과 폭주문제가 발생할 확률이 높아진다. 이러한 문제를 보완하기 위해 처음 11-Layer 정규분포를 따르는 랜덤한 가중치로 네트워크를 사전 학습 후 학습된 가중치를 입력 4개의 층과 마지막 3개의 층의 초기 가중치 값으로 사용한다.

하지만 그림과 같이 합성곱 연산에서 피쳐맵의 크기가 일정하고, 풀링 연산에서만 피쳐맵의 크기가 조절되기에 네트워크 모델이 비교적 단순하기에 현재까지도 많이 사용하는 딥러닝 모델 중 하나이다.

3.2.2 VGG19

VGG19는 16개의 합성곱층과 3개의 완전 연결층으로 구성되어 있다. [표3-3]와 같이 VGG16에 비해 3개의 합성곱 층이 추가되었으며 모델의 파라미터의 수는 144,000,000개로 VGG16보다 6,000,000개의 파라미터가 많다. 파라미터의 수가 많아진 만큼 연산비용이 커지게 되고, 과적합될 우려가 있기에 VGG19보다 VGG16이 범용적으로 사용된다.

[표3-3] VGG19 구조

	층 구성	피쳐맵 크기
입력 층	RGB 이미지	(224, 224, 3)
층 1	합성곱 계층 - 64개의 필터	(224, 224, 64)
층 2	합성곱 계층 - 64개의 필터	(224, 224, 64)
풀링 층 1	맥스 풀링	(112, 112, 64)
층 3	합성곱 계층 - 128개의 필터	(112, 112, 128)
층 4	합성곱 계층 - 128개의 필터	(112, 112, 128)

풀링 층 2	맥스 풀링	(56, 56, 128)
층 5	합성곱 계층 - 256개의 필터	(56, 56, 256)
층 6	합성곱 계층 - 256개의 필터	(56, 56, 256)
층 7	합성곱 계층 - 256개의 필터	(56, 56, 256)
층 8	합성곱 계층 - 256개의 필터	(56, 56, 256)
풀링 층 3	맥스 풀링	(28, 28, 256)
층 9	합성곱 계층 - 512개의 필터	(28, 28, 512)
층 10	합성곱 계층 - 512개의 필터	(28, 28, 512)
층 11	합성곱 계층 - 512개의 필터	(28, 28, 512)
층 12	합성곱 계층 - 512개의 필터	(28, 28, 512)
풀링 층 4	맥스 풀링	(14, 14, 512)
층 13	합성곱 계층 - 512개의 필터	(14, 14, 512)
층 14	합성곱 계층 - 512개의 필터	(14, 14, 512)
층 15	합성곱 계층 - 512개의 필터	(14, 14, 512)
층 16	합성곱 계층 - 512개의 필터	(14, 14, 512)
풀링 층 5	맥스 풀링	(7, 7, 512)
플래튼	플래튼	(25088,)
층 17	완전연결층 - 4096개의 뉴런	(4096,)
층 18	완전연결층 - 4096개의 뉴런	(4096,)
층 19	완전연결층 - 1000개의 뉴런	(1000,)
소프트맥스	소프트맥스	(분류하고자하는 클래스 수,)

3.3 Inception

Inception[26]은 2014년 ILSVRC에서 우승한 모델로, CNN의 네트워크를 깊게 구축하여 성능을 올리고자 하였다. 앞의 내용과 마찬가지로 모델 네트워크의 깊이를 깊게할수록 과적합, 그레디언트 소실, 연산량 증가의 문제가 발생한다. 이를 드롭아웃을 사용하여 희소한 구조를 만들어 해결하고자 하였지만 하드웨어의 연산은 밀집한 구조에서 성능이 발휘되어 Inception 모듈을 만들어 해결하고자 하였다.

3.3.1 InceptionV1

Inception 모듈에서는 다양한 크기의 필터 사이즈를 통해 객체의 특징을 추출하고 인접한 노드 간 연결을 통해 희소한 특징 추출 구조를 만들되 행렬 연산 밀집하게 처리하기 위하여 합성곱 연산을 더 작은 합성곱 연산의 조합으로 쪼개어 합치는 인셉션 모듈을 만들어 해결하고자 하였다.

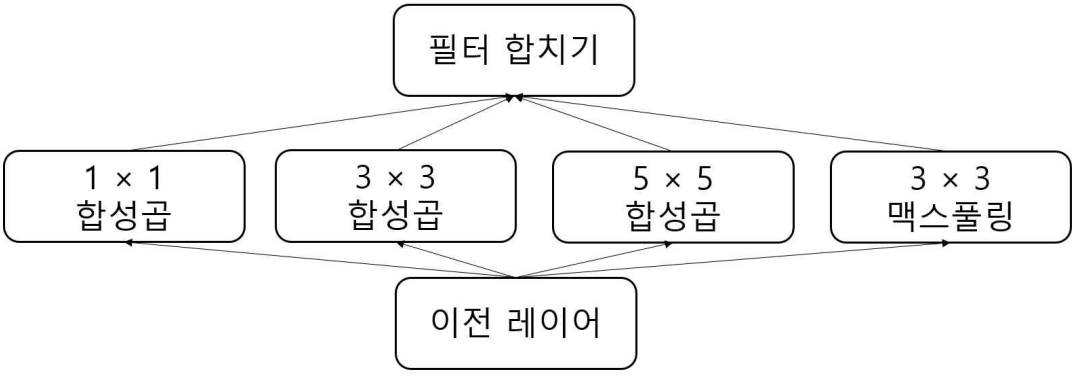

[그림3-6] 초기 인셉션 모듈

이러한 행렬 연산도 여전히 많은 연산 비용을 발생시키는데, [그림3-7]와 같이 1×1 합성곱 필터를 통해 채널을 조절하여 계산량을 감소시킨다. 이러한 필터는 활성화 함수를 포함하기에 모델의 비선형성을 증가시킨다는 이점이 존재한다.

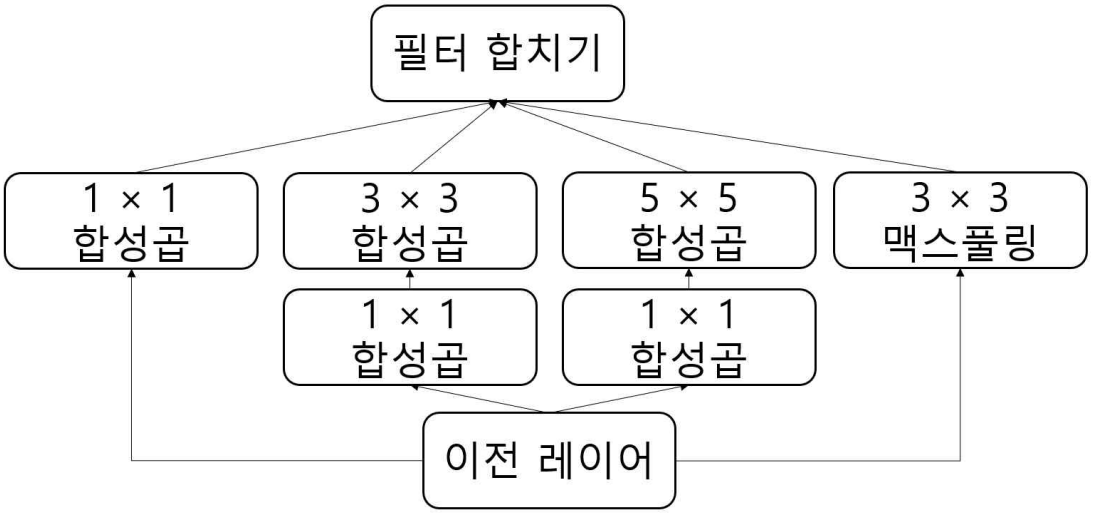

[그림3-7] 1×1 합성곱 필터를 사용한 인셉션 모듈

3.3.2 InceptionV2

InceptionV1은 인셉션 모듈과 모델 구성 자체가 복잡하여 응용하여 사용하기 어려우며 여전히 합성곱은 연산량이 많다. 이에 InceptionV2[27]를 통해 모델을 단순화하고 VGG에서 효과가 좋았던 3×3 합성곱 필터를 모든 네트워크 구조에 적용한다. [그림3-8] (b)와 같이 InceptionV1 모듈에서 사용했던 5×5 합성곱 필터를 3×3 합성곱 필터 2개로 교체한다. 또한 [그림3-8] (c), (d)와 같이 연산량을 더욱 줄이기 위하여 N×N 합성곱 연산을 N×1, 1×N 비대칭으로 쪼개어 합성곱 연산을 하며 연산량의 33%를 절약하는 이점이 있다.

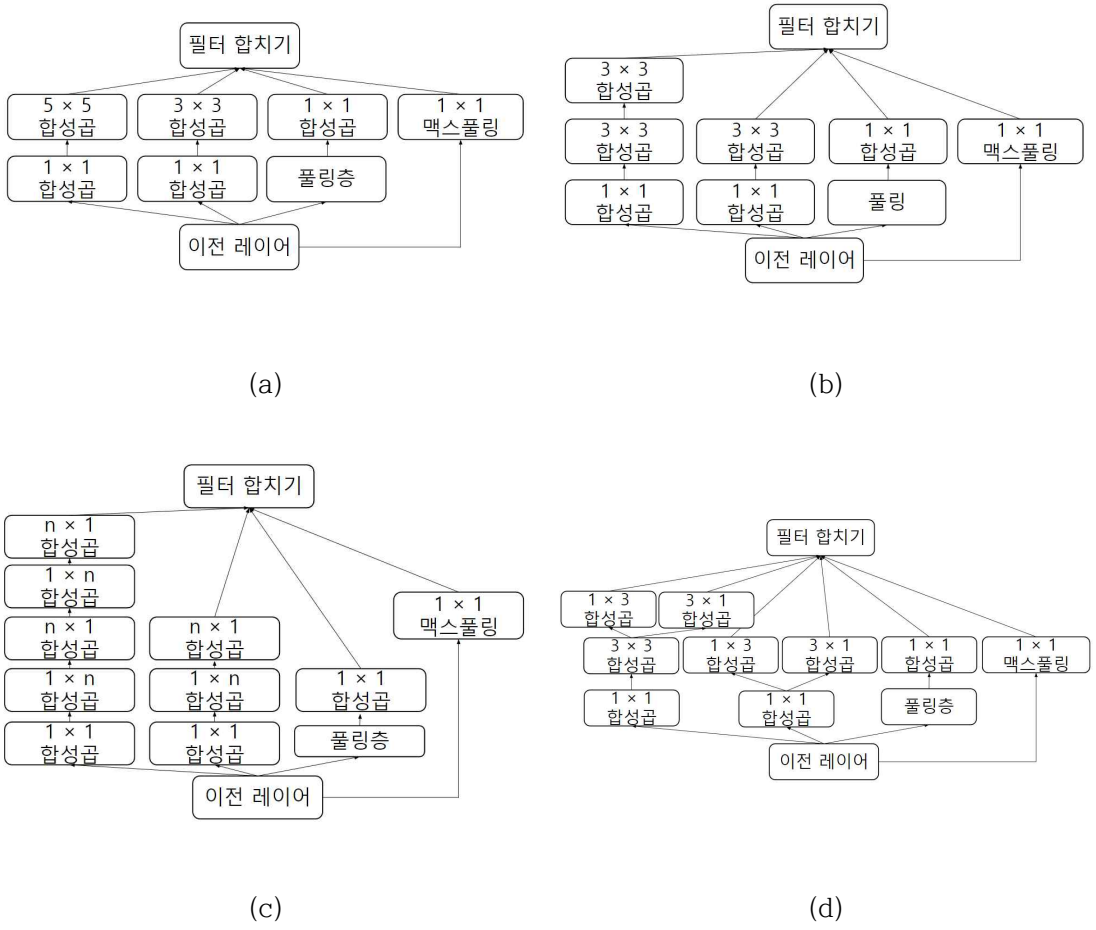

[그림3-8] Inception 모듈
(a) InceptionV1 모듈 (b) InceptionV2 모듈
(c) InceptionV2 모듈(비대칭) (d) InceptionV2 모듈(비대칭)

3.3.3 InceptionV3

InceptionV3는 InceptionV2 구조에 기반하여 다양한 기법들을 테스트해보며 성능에 좋은 영향을 미친 조건들을 추가한 모델로 구성은 InceptionV2와 동일하다. 성능을 개선하기 위해 옵티마이저를 RMSProp으로 변경하였으며, 보조분류기를 도입하여 정규화 성능을 올리고자 하였다. 또한 일반적인 분류 모델에서 사용하는 라벨값의 형태인 원 핫 인코딩으로 라벨을 설정하지만 오답인 값에 대해서 작은 값을 주어 정답 값에 대한 확신을 주지 못하게 하는 라벨 스무딩 기법을 적용한다. 라벨 스무딩된 타겟 값 y^{LS}는 분류하고자 하는 클래스의 수 K와 스무딩 파라미터 α와 함께 표현된다.

$$y^{LS} = y(1-\alpha) + \alpha/K \tag{17}$$

Inception 모델은 42개의 층으로 이루어져 있으며, 모델의 구성은 [표3-4]와 같다.

[표3-4] Inception 구조

	층 구성 **(필터사이즈, 필터개수, 스트라이드, 패딩적용 유무)**	**결과 피쳐맵 크기**
입력 층	RGB 이미지	(299, 299, 3)
합성곱 층 1	3×3, 32, 2	(149, 149, 32)
합성곱 층 2	3×3, 32, 1, padded	(147, 147, 32)
풀링 층 1	3×3, 64, 1	(147, 147, 64)
합성곱 층 3	3×3, 64, 2	(73, 73, 64)
합성곱 층 4	3×3, 64, 1	(71, 71, 80)
합성곱 층 5	3×3, 64, 2	(35, 35, 192)
합성곱 층 6	3×3, 64, 1	(35, 35, 288)
3×인셉션모듈1	[그림3.3.2-2]	(17, 17, 768)
5×인셉션모듈2	[그림3.3.2-3]	(8, 8, 1280)
2×인셉션모듈3	[그림3.3.2-4]	(8, 8, 2048)
풀링 층2	8×8	(1, 1, 2048)
완전연결층1	1000개의 뉴런	(1, 1, 1000)
소프트맥스	소프트맥스	(분류하고자하는 클래스 수,)

3.4 모델 평가지표

모델의 성능을 평가한다는 것은 정답 값과 모델에 의해 출력된 값의 오차를 구하는 것을 말한다. 정답 값과 비교해야한다는 점에서 지도학습 모델에서 사용할 수 있으며, 오차의 값이 작을수록 모델의 성능이 좋다는 것을 알 수 있다. 모델은 크게 연속형 데이터를 예측하는 회귀 모델과 범주형 클래스에 대하여 정답 클래스를 예측하는 분류 모델로 나뉜다. 본 논문은 정답 라벨이 있는 지도 학습 모델을 사용하며, 얼굴 이미지에 대하여 7가지 감정에 대하여 정답 값을 예측하는 분류 모델을 사용한다.

3.4.1 분류 모델 성능 평가지표

분류 모델의 성능을 평가하기 위해서는 모델의 의해 예측된 범주와 실제 데이터의 범주를 [표3-5]와 같이 교차형태로 정리한 지표를 사용한다.

[표3-5] 오차 행렬

		예측 값	
		예측 정답 값	예측 틀린값
실제 값	실제 정답 값	True Positive(TP)	False Negative(FN)
	실제 틀린 값	False Positive(FP)	True Negative(TN)

전체 데이터 중에서, 모델에 의해 정확하게 예측된 데이터의 수의 비율을 나타낸 지표를 정확도라고 한다. 정확도라는 지표는 데이터셋이 클래스별로 데이터 수의 차이가 많이 날 경우 특정 데이터에 과적합되어 높은 정확도를 보일 수 있는 한계점이 있다. 이는 데이터 불균형에는 적합한 평가지표가 아님을 알 수 있다. 정확도를 구하는 공식은 다음과 같다.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{18}$$

모델이 정답 값이라고 예측한 데이터 중에 실제 데이터가 정답일 확률의 지표를 정밀도라고한다. 정밀도는 실제 틀린 값인데 모델이 정답 값으로 예측하는 FP를 낮추어 확률을 올리는 것을 목표로 하는 지표이다. 정밀도의 수식은 다음과 같다.

$$\mathrm{Pr}ecision = \frac{TP}{TP + FP} \tag{19}$$

실제 값이 정답인 경우에서 모델이 예측한 정답 값이 정답일 확률의 지표를 민감도 혹은 재현율이라고 한다. 재현율은 실제 정답 값인데 모델이 틀린 값으로 예측하는 FN을 낮추어 확률을 올리는 것을 목표로 하는 지표이다. 재현율을 구하는 수식은 다음과 같다.

$$Recall = \frac{TP}{TP + FN} \quad (20)$$

[그림3-9]와 같이 정밀도이 커지면 정밀도는 작아지는 정밀도와 재현율은 트레이드오프 관계를 보인다.

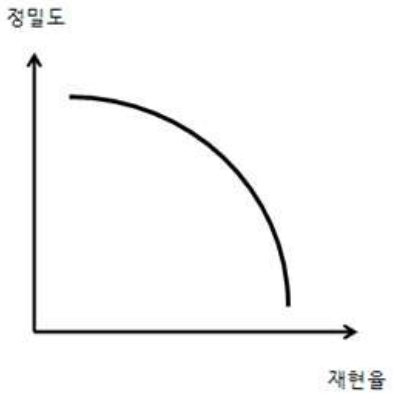

[그림3-9] 재현율과 정밀도

두가지 지표의 조화평균을 사용하는 지표가 F1 점수이다. F1 점수의 수식은 다음과 같다.

$$F1\,score = 2 \times \frac{Recall \times \mathrm{Pr}ecision}{Recall + \mathrm{Pr}ecision} \quad (21)$$

F1 점수는 데이터가 불균형한 경우에 특히 적합한 평가 지표로서, 정밀도와 재현율의 조화 평균으로 계산된다. 이는 작은 클래스에 대한 성능을 정확하게 반영하면서도 각 클래스의 샘플 수에 영향을 받지 않는 특성을 지니고 있어 불균형한 데이터셋에서 정확도와는 차별화된 강건한 성능 평가를 제공한다.

본 연구는 얼굴 이미지 감정 분류에서의 데이터 불균형을 고려하며, 정확도와 더불어 F1 점수를 추가 지표로 활용하여 모델의 성능을 불균형에 강건하게 평가하고자 한다.

4. 제안 알고리즘

본 논문에서 제안하는 알고리즘은 얼굴 표정 분류의 정확도를 향상시키기 위해 합성곱 기반 네트워크에 랜드마크 기반 완전 연결 네트워크를 추가하는 방식이다. 먼저, 본 논문에서 사용하는 CNN 기반 네트워크는 VGG와 Inception 네트워크로, 관련 연구에서 소개된 네트워크[15,16]를 참고한다.

4-1 랜드마크 특징 수 조절

본 논문에서 제안하는 알고리즘은 합성곱 기반 네트워크에 랜드마크 기반 완전 연결 네트워크를 추가함으로서 얼굴 표정 분류 정확도를 높이고자 한다. 합성곱 기반 네트워크의 기본 아키텍처로 VGG16과 InceptionV3를 채택하였으며, 7가지 감정을 분류하는데 용이하도록 각 네트워크를 튜닝한다. Keras API가 제공하는 VGG16, inceptionV3의 분류기 입력 특성맵의 크기는 [표4-1]와 같다.

[표4-1] VGG, Inception 분류기 피쳐맵 크기

CNN 네트워크	분류기 이전 피쳐맵 크기	분류기 입력 피쳐맵 크기
VGG16	(7, 7, 512)	(25088,)
InceptionV3	(8, 8, 2048)	(2048,)

본 논문은 랜드마크 추가의 유의미함을 알아보기 위한 실험으로 두 네트워크가 합쳐질 때 특성의 개수를 합치는 방법을 알아본다. CNN 네트워크의 경우 분류기 이전 특성맵의 크기로 VGG16은 InceptionV3와 같이 Global Average Pooling을 통하여 특성의 수를 512개, InceptionV3는 2048개의 특성를 가지도록 모델을 구축한다. 이에 MLP 네트워크의 마지막 층의 특성맵의 크기를 선택한다.

두 네트워크가 합쳐지는 곳에서 이미지 특성맵과 랜드마크 특성맵을 조합하는 방식에 대하여 2가지의 경우에 대하여 실험적 결과를 통해 특성맵의 크기를 조절한다.

본 논문에서 사용하는 이미지의 경우 80×80×3의 크기로 총 19,200개 특성이 있는반면 얼굴 이미지에서 추출한 랜드마크의 경우 68×2의 크기로 총 136개의 특성을 가진다. 이는 이미지의 특성에 비해 현저히 작은 숫자이다. MLP 네트워크의 구성은 [그림4-1]과 같으며, 두가지의 특성맵을 효과적으로 합치기 위하여 입력 크기의 비례하게 특성맵을 합치는 방법과 두가지 정보를 중요도를 동일하게 취급하여 동등하게 특성맵을 합치는 방법을 실험적 결과로 선택한다. 이는 5-4에서 확인할 수 있다.

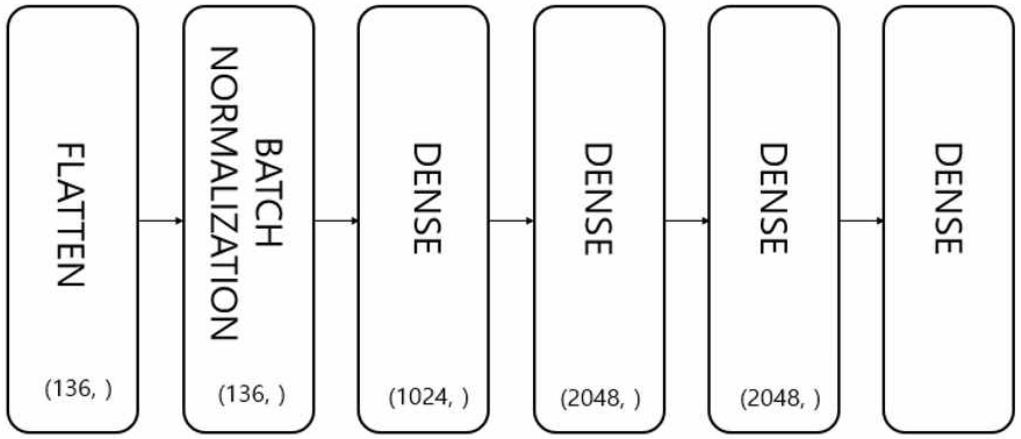

[그림4-1] MLP 네트워크 구조

4-2 FACS 방법론 기반 특징점 추가

우리는 이미지 정보 뿐만 아니라 Paul Ekman[28]에 의해 개발된 FACS(Facial Action Coding System) 방법론을 기반으로 하여 의미 있는 랜드마크 정보를 추가한다. FACS는 얼굴 표정을 체계적으로 분석하고 이해하기 위한 방법론 중 하나로, 되었다. FACS 방법론은 얼굴 표정을 설명하는 여러 액션 유닛(AU)를 정의한다. 액션 유닛은 특정 얼굴 근육 또는 근육 그룹의 활성화 또는 억제로 인해 발생하는 얼굴 표정의 세분화된 단위이다.

액션 유닛은 [표4-2]과 같이 1부터 44까지 번호가 매겨져 있으며[29], 각 액션 유닛은 특정 표정을 나타내기 위해 특정 얼굴 근육과 연결된다. 이는 얼굴 표정의 핵심 구성 요소를 설명하며, 다양한 액션 유닛의 조합을 통해 다양한 얼굴 감정을 표현할 수 있다.

[표4-2] FACS 액션 유닛

액션 유닛	설명	예제 이미지
1	Inner Brow Raiser	
2	Outer Brow Raiser	
4	Brow Lowerer	
5	Upper Lid Raise	

6	Cheek Raiser	
7	Lid Tightener	
9	Nose Wrinkler	
10	Upper Lip Raiser	
11	Nasolabial Deepener	
12	Lip Corner Puller	
13	Cheek Puffer	
14	Dimpler	
15	Lip Corner Depressor	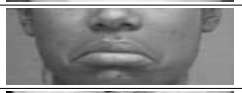
16	Lower Lip Depressor	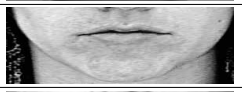
17	Chin Raiser	
18	Lip Puckerer	
20	Lip stretcher	
22	Lip Funneler	
23	Lip Tightener	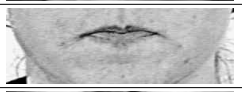
25	Lips part	
26	Jaw Drop	
27	Mouth Stretch	
28	Lip Suck	
41	Lid droop	

42	Slit	
43	Eyes Closed	
44	Squint	

최동운[30]은 기본 감정을 구현하기 위한 액션 유닛의 조합을 제안하였다. 이러한 액션 유닛에 대응되는 랜드마크를 찾고 랜드마크 간 거리값을 MLP 네트워크 특징점에 추가한다. 행복 상태에서는 긍정적인 감정이나 웃음과 관련된 얼굴의 볼이 올라가는 상태를 나타내는 액션 유닛 6번을 랜드마크 37번과 46번 좌표간의 거리 값, 양쪽 입술의 끝이 옆으로 움직이는 상태를 나타내는 액션 유닛 12번을 랜드마크 49번과 55번 좌표간의 거리 값으로 나타낸 뒤 특징에 포함시켰다.

화남 상태에서는 부정적인 감정인 불만, 분노와 관련된 특징을 나타내기 위해 이마 부분의 피부가 아래로 움직이는 상태를 나타내는 액션 유닛 4번을 랜드마크 22번과 23번 좌표간의 거리값, 눈꺼풀이 위로 올라가는 상태를 나타내는 액션 유닛 5번을 랜드마크 39번과 41번, 44번과 48번 좌표간의 거리값으로 표현했으며,
눈꺼풀 주변의 피부가 긴장되어 닫힌 상태를 나타내는 액션 유닛 7번을 랜드마크 40번과 43번 좌표간의 거리값, 그리고 입술 주변의 근육이 수축하여 입술을 긴장시키는 상태를 나타내는 액션 유닛 23번을 랜드마크 9번과 58번 좌표간의 거리값으로 나타낸 뒤 특징에 포함시켰다.

역겨움 상태에서는 불만이나 코가 찡그러진 표현과 관련된 특징을 나타내기 위해 코 주변의 피부가 주름지는 상태를 나타내는 액션 유닛 9번을 랜드마크 32번과 40번, 36번과 43번 좌표간의 거리 값, 입술의 모서리가 아래로 움직이는 상태를 나타내는 액션 유닛 15번을 랜드마크 32번과 49번, 36번과 55번 좌표간의 거리값, 그리고 하품이나 입을 벌린 상태에서 움직임을 나타내는 상태를 나타내는 액션 유닛 16번을 랜드마크 9번과 49번, 9번과 55번 좌표간의 거리값으로 나타낸 뒤 특징에 포함시켰다.

두려움 상태에서는 부정적인 감정이나 걱정과 관련된 특징을 나타내기 위해 이마의 내측 부분이 위로 올라가는 상태를 나타내는 액션 유닛 1번을 랜드마크 22번과 40번, 23번과 43번 좌표간의 거리 값, 이마의 바깥쪽 부분이 위로 올라가는 상태를 나타내는 액션 유닛 2번을 랜드마크 18번과 37번, 27번과 46번 좌표간의 거리 값으로 표현했으며, 이마 부분의 피부가 아래로 움직이는 상태를 나타내는 액션 유닛 4번을 랜드마크 22번과 23번 좌표간의 거리 값, 눈꺼풀이 위로 올라가

는 상태를 나타내는 액션 유닛 5번을 랜드마크 39번과 41번, 44번과 48번 좌표간의 거리값, 입술을 늘리는 상태를 나타내는 액션 유닛 20번을 랜드마크 58번과 67번 좌표간의 거리값, 그리고 턱이 내려가는 상태를 나타내는 액션 유닛 26번을 랜드마크 34번과 52번, 9번과 58번 좌표간의 거리값으로 나타낸 뒤 특징에 포함시켰다.

슬픔 상태에서는 두려움과 화남 상태에서 언급된 특징점들을 기반으로 특징점을 선정하였으며, 놀라움 상태는 두려움 상태에서 언급된 유닛 중 놀라움, 경악, 혹은 놀람 감정과 관련된 액션 유닛 1번, 2번, 26번을 기반으로 선정하였다.

선정한 랜드마크간 거리 정보는 [표4-3]에서 확인할 수 있다.

[표4-3] 액션유닛에 대응되는 랜드마크

감정	액션 유닛 조합 (랜드마크 번호(시작점-끝점))
행복함	6(37-46), 12(49-55), 37-49, 46,55
화남	4(22-23), 5(39-41, 44-48), 7(40-43), 23(9-58)
역겨움	9(32-40, 36-43), 15(32-49, 36-55), 16(9-49, 9-55)
두려움	1(22-40, 23-43), 2(18-37, 27-46), 4(22-23), 5(39-41, 44-48), 20(58-67), 26(34-52, 9-58)
중립	-
슬픔	1(22-40, 23-43), 4(22-23), 15(32-49, 36-55)
놀람	1(22-40, 23-43), 2(18-37, 27-46), 26(34-52, 9-58)

추가 특징점의 정보를 시각적으로 나타내면 [그림4-2]과 같다.

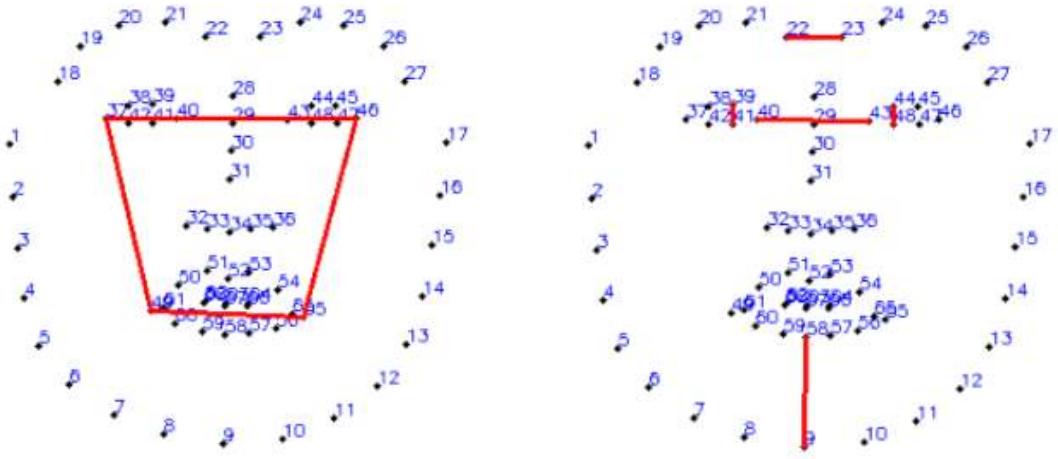

(a) (b)

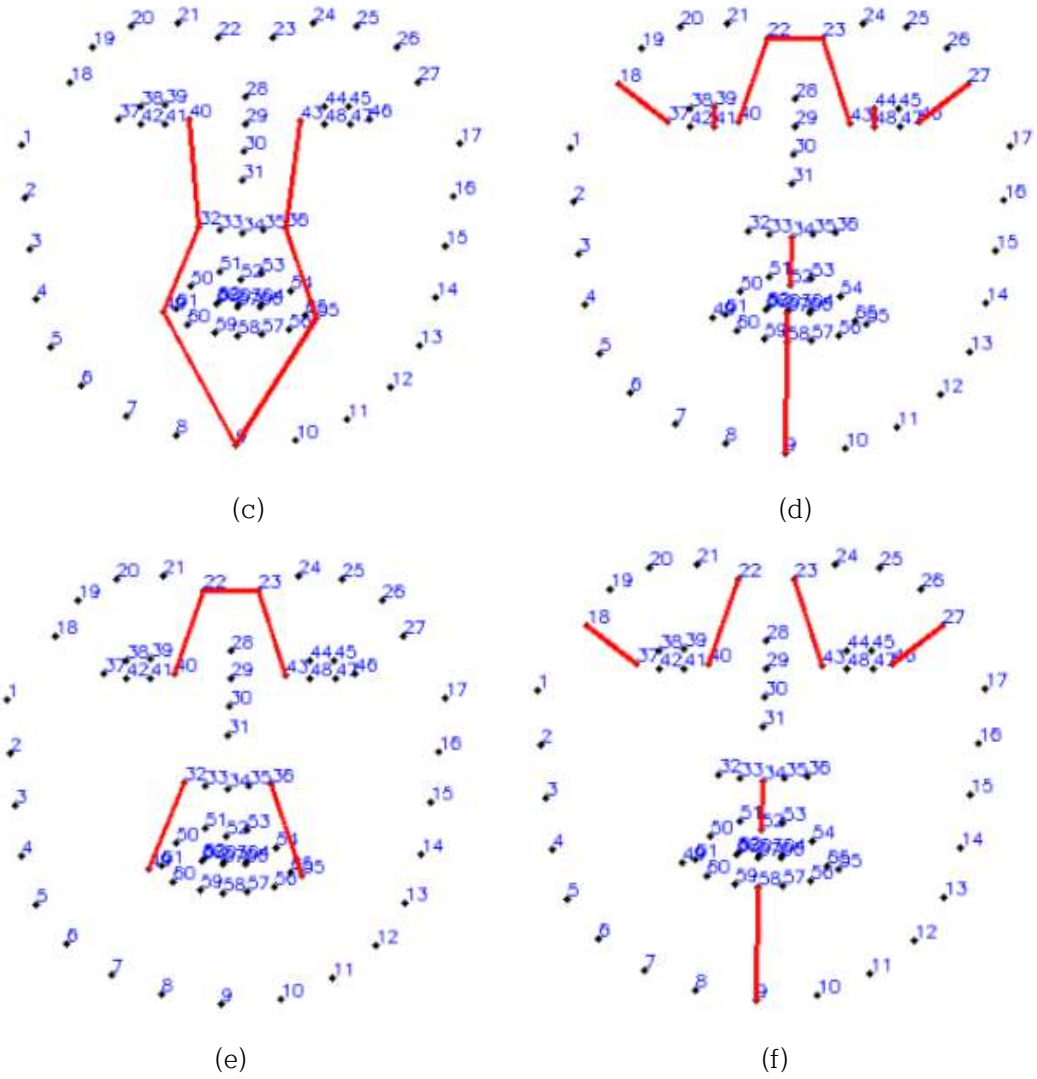

[그림4-2] 액션 유닛의 조합에 대응되는 랜드마크 간 거리정보 선정
(a) 행복함 (b) 화남 (c) 역겨움 (d) 두려움 (e) 슬픔 (f) 놀람

FACS 방법론을 기반하여 추가한 특징의 수는 총 88개이다. 이에 대한 유용성은 5-5에서 실험적 결과로 보이고자 한다.

4-3 CNN 네트워크와 MLP 네트워크 합치는 통합 네트워크 제안

본 논문은 CNN기반 네트워크에 랜드마크를 추가함으로써 얼굴 이미지에 대한 감정분류 모델 성능을 향상 시키고자한다. 제안하는 모델의 구조는 [그림4-3]과 같이 완전 연결 네트워크와 합성곱 기반 네트워크로 구성된 Two-stream-network로 설계한다. MLP 네트워크로는 얼굴 이미지에서 ASM 알고리즘을 통해 추출된 랜드마크와 FACS 방법론을 참고하여 특징점을 추가한 벡터가 입력으로 사용한다. CNN 네트워크로는 VGG16과 Inception 네트워크를 기본 아키텍처로 사용하며 데이터셋 이미지를 입력으로 사용한다. 얼굴 이미지에 대한 감정을 분류한다.

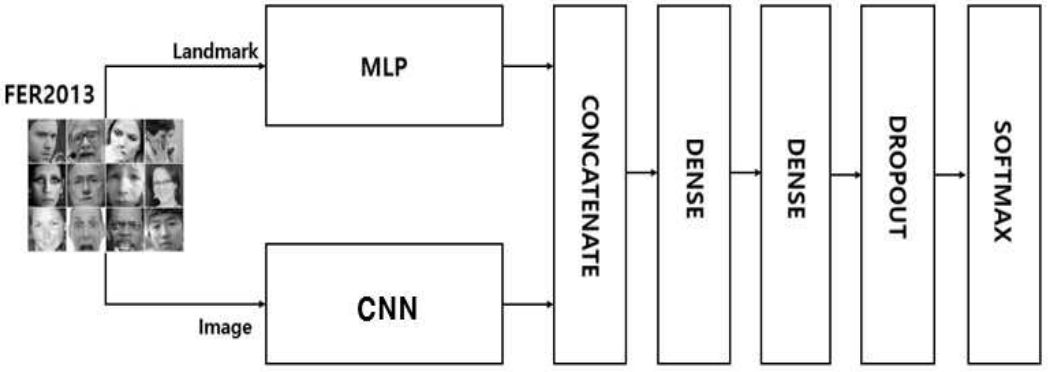

[그림4-3] 제안 알고리즘 구조

5. 실험

5.1 데이터셋

angry disgust fear neutral sad surprise happy

[그림5-1] FER2013 클래스별 이미지

제안된 논문에서 사용한 이미지 데이터셋은 FER2013 데이터셋이다. 이 데이터셋은 Kaggle에서 제공되는 공개 데이터셋으로, 얼굴 이미지와 해당 이미지에 대한 감정 표현 레이블이 제공된다. 데이터셋은 [표5-1]와 같이 훈련 데이터와 테스트 데이터로 구성되어 있으며, 이 데이터는 모두 48x48 크기의 그레이 스케일 이미지로 이루어져 있다.

훈련 데이터는 총 28,709개의 이미지로 구성되어 있으며, 테스트 데이터에는 3,589개의 이미지가 포함되어 있다. 이 데이터셋은 다양한 감정 상태를 포함하고 있으며, 이것은 그림 10에서 확인할 수 있다. 감정 상태는 화남, 역겨움, 공포, 두려움, 행복, 슬픔 및 중립으로 총 7개의 클래스로 분류된다.

위 데이터셋은 감정 인식 및 분류 모델의 훈련과 평가에 적합한 다양한 감정 상태를 다루는 데 사용된다.

[표5-1] FER2013 클래스 별 데이터 분포

	angry	disgust	fear	happy	neutral	sad	surprise
train	3995	436	4097	7215	4965	4830	3171
test	958	111	1024	1774	1233	1247	831

5.2 전처리

Keras API의 InceptionV3 모델은 입력 이미지의 크기로 최소한 75 이상의 너비와 높이를 가진 3채널 RGB 이미지를 요구한다. 따라서 훈련 데이터와 테스트 데이터의 모든 이미지는 이 요구사항에 부합하도록 80x80 크기의 RGB 이미지로 변환한다.

또한, 얼굴의 크기가 작거나 해상도가 낮은 이미지, 그리고 얼굴이 부분적으로 잘려 얼굴 형태를 명확하게 구분하기 어려운 이미지는 랜드마크 인식 과정에 어려움을 겪을 수 있으므로, 이러한 이미지들은 임의로 제거함으로써 모델의 훈련 데이터의 품질을 향상시켰다.

[표5-2] FER2013 전처리 후 클래스 별 데이터 분포

	angry	disgust	fear	happy	neutral	sad	surprise
train	2757	341	2537	5605	3731	2664	2358
test	642	86	646	1381	931	665	611

5.3 데이터 증강

FER2013 데이터셋에서 발견된 주요 문제 중 하나는 역겨움 클래스에 대한 훈련 데이터가 340개로, 다른 클래스 중 하나인 행복함의 5620개의 훈련 데이터에 비해 현저히 적다는 것이다. 이러한 데이터 불균형 문제는 모델의 학습 과정에서 특정 클래스에 과적합되는 경향을 낳을 수 있다. 이로 인해 전체적인 정확도는 향상시킬 수 있지만, 역겨움 클래스와 같이 데이터가 부족한 클래스에 대한 예측 성능이 저하될 수 있다.

위 문제를 해결하기 위해 데이터 증강 기법을 도입하였다. 좌우 반전, 회전, 확대, 축소와 같은 데이터 증강 기법을 적용하여 훈련 이미지를 다양한 방식으로 변형하였다. 이러한 과정을 통해 데이터의 다양성을 확보하고 역겨움 클래스와 같은 데이터가 부족한 클래스에 대한 모델의 학습을 강화하였다. [그림5-2]은 하나의 샘플이미지에 대한 증강 예시를 보인다.

(a) (b) (c) (d)

[그림5-2] 이미지에 대한 데이터 증강
(a) 원본 이미지 (b) 좌우대칭, 10% 확대
(c) 10도 회전, 10% 확대 (d) 좌우대칭

5.4 MLP 네트워크 특성맵 조절

4-1에서 확인할 수 있듯이 분류기 이전에서 VGG 512개, Inception 2048개 특성맵의 크기를 가지고 있다. 이에 MLP 네트워크의 마지막 특성맵의 크기를 실험적 결과로 선택하고자 하며, 이미지의 특성 개수와 랜드마크의 특성 개수의 비율을 고려하여 128개의 특징과, 비슷한 특성 개수인 1024개의 특징의 특성맵을 가지게 실험한다. [그림5-3]은 VGG 네트워크와 MLP 네트워크를 통합하는 순간의 모습을 보인다.

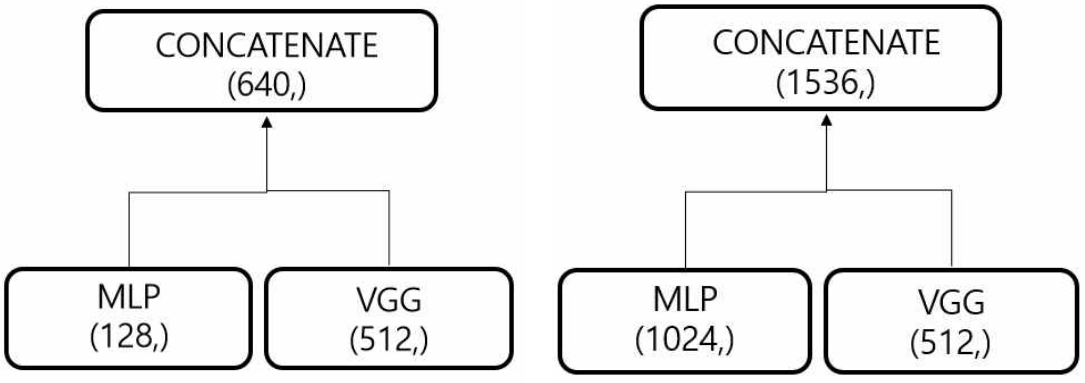

(a) (b)

[그림5-3] VGG 네트워크와 MLP 네트워크 통합
(a) MLP 네트워크의 특성맵 크기가 (128,)인 경우
(b) MLP 네트워크의 특성맵 크기가 (1024,)인 경우

[그림5-3]의 (a)와 같이 MLP 네트워크의 결과 특성맵의 크기가 (128,)일 때, 통합 네트워크의 정확도는 64.8%로 나왔으며, [그림5-3]의 (b)와 같이 특성맵의 크기가(1024,) 인 경우 네트워크의 정확도는 65.7%로 0.9% 상승함을 확인할 수 있다.

마찬가지로 [그림5-4]는 Inception 네트워크와 MLP 네트워크를 통합하는 순간의 모습을 보인다.

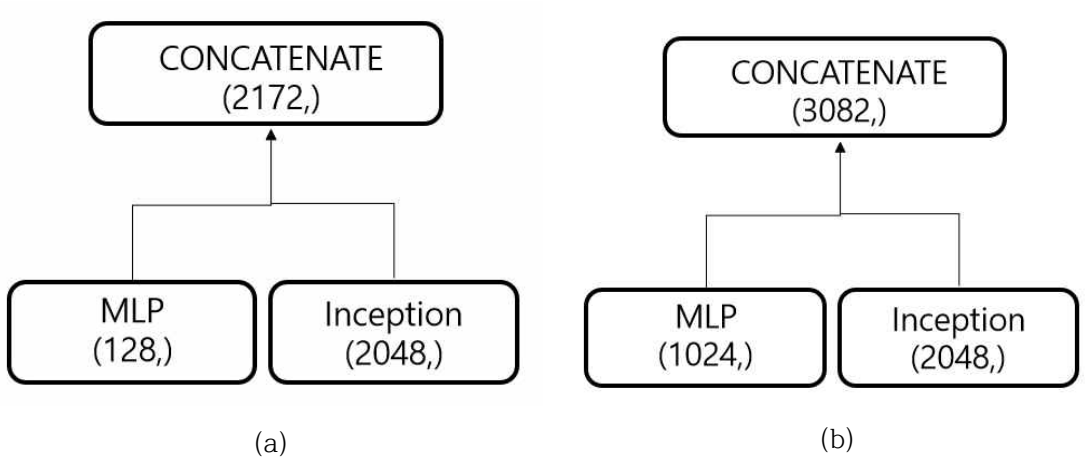

[그림5-4] Inception 네트워크와 MLP 네트워크 통합
(a) MLP 네트워크의 특성맵 크기가 (128,)인 경우
(b) MLP 네트워크의 특성맵 크기가 (1024,)인 경우

[그림5-4]의 (a)와 같이 MLP 네트워크의 결과 특성맵의 크기가 (128,)일 때, 통합 네트워크의 정확도는 65.2%로 나왔으며, [그림5-4]의 (b)와 같이 특성맵의 크기가(1024,) 인 경우 네트워크의 정확도는 65.7%로 0.5% 성능이 좋음을 확인할 수 있다. 통합네트워크의 사용되는 VGG, Inception 두 네트워크 모두 MLP의 특성맵의 크기가 (1024,) 일 때 (128,)에 비해 0.9%, 0.5% 상승함을 알 수 있다.

[표5-3] MLP 결과 특성맵에 따른 정확도 비교

	MLP 결과 특성맵 크기 (128,)	MLP 결과 특성맵 크기 (1024,)	정확도 상승
VGG	64.8%	65.7%	0.9%
Inception	65.2%	65.7%	0.5%

5.5 FACS 방법론 기반 정보 추가

68개의 랜드마크 정보는 이미지의 정보를 효과적으로 표현하기에 부족하다. 이에 FACS 방법론을 기반하여 랜드마크 간 거리 정보를 추가하여 이에 대한 효과를 보이고자 한다. CNN 네트워크로 Inception 네트워크를 사용한 경우, 검증 정

확도 67.8%에서 FACS에 따라 거리 정보를 추가함으로써 69.2% 검증 정확도로 1.4% 상승하였다. 이는 [그림5-5] (a)와 (b)를 통해 확인할 수 있다. 또한 [그림5-5]의 (c)와 (d)와 같이 Inception 네트워크를 사용한 경우 65.9%에서 66.7%로 0.8% 상승함을 확인할 수 있다.

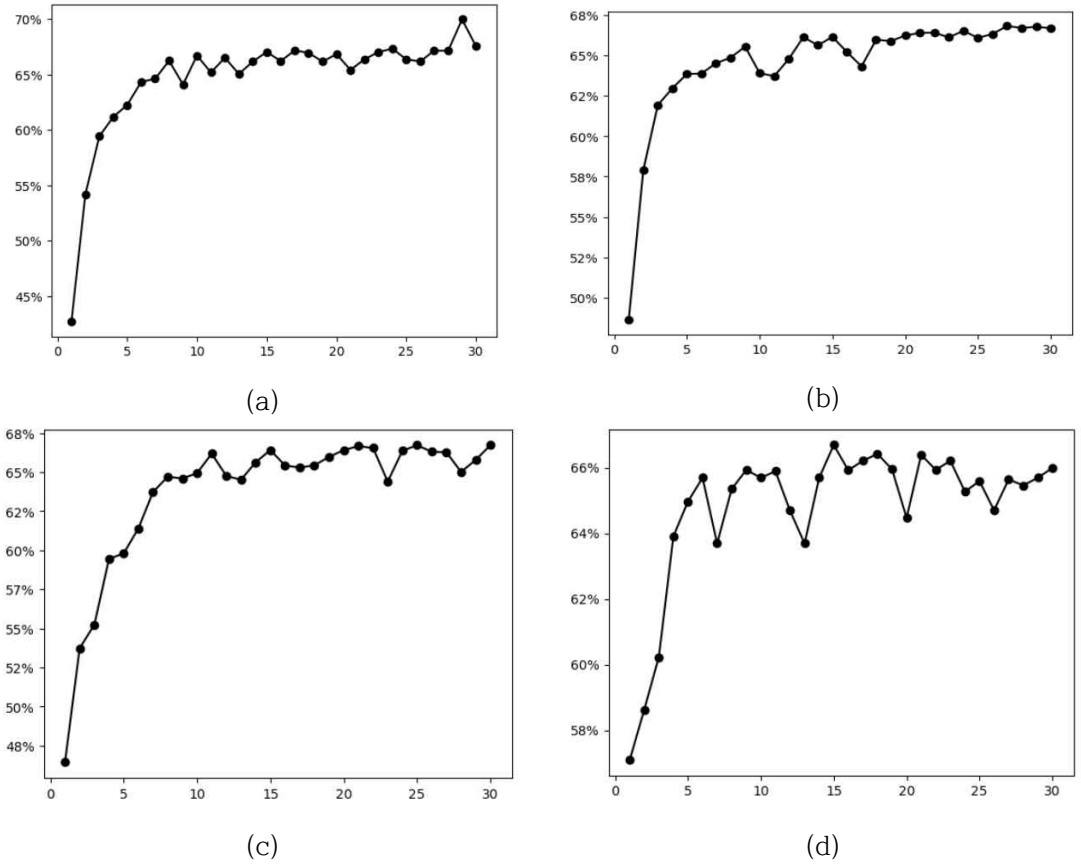

[그림5-5] FACS 방법론 기반 정보추가한 경우 알고리즘 정확도 비교
(a) Inception + Landmark (b) Inception + Landmark(FACS기반 정보추가)
(c) VGG + Landmark (d) VGG + Landmark(FACS기반 정보추가)

VGG, Inception 두 개의 네트워크 모두 FACS 방법론을 기반하여 랜드마크를 추가함으로써 더 좋은 성능을 보이는 것을 확인할 수 있다. 아래 [그림5-6]에서 검은색 선은 랜드마크만 추가하였을 경우이며, 파란색 선은 랜드마크에 추가적으로 정보를 추가한 경우이다.

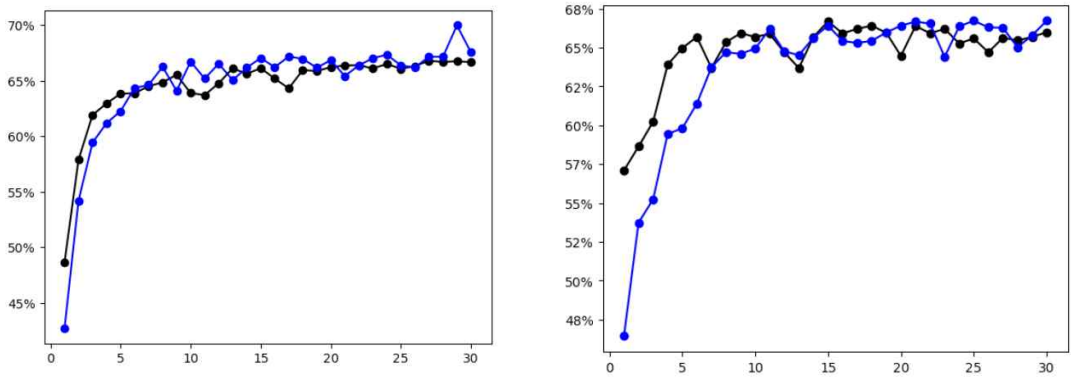

(a) (b)

[그림5-6] FACS 방법론 기반 특징추가 유무에 따른 정확도 비교
(a) Inception에서 FACS 추가 후 정확도 비교
(b) VGG에서 FACS 추가 후 정확도 비교

5.6 실험 결과

본 논문이 제안하는 방법은 랜드마크 정보를 추가하여 얼굴이미지에 따른 감정 분류의 정확도를 올리는 것이다. [표5-4]에서 확인할 수 있듯이 랜드마크 정보를 추가함으로서, VGG네트워크는 67.75%에서 69.02%로 1.27%, Inception 네트워크는 68.32%에서 69.31%로 0.99% 정확도가 상승한 것을 확인할 수 있다.

[표5-4] 제안 알고리즘 정확도 비교

네트워크 구성	정확도
VGG	67.75%
Inception	68.32%
VGG+MLP(제안)	69.02%
Inception+MLP(제안)	69.31%

또한 얼굴의 감정의 보편적인 특징을 랜드마크 기반으로 특징점을 추가하여 다양한 개체와 환경에서 일반화 성능을 향상시키는 것을 목표로 하였다.

[그림5-7]를 통해 VGG 네트워크에 대하여 랜드마크 추가에 따른 비교한 오차행렬을 확인할 수 있다. 단일 네트워크의 경우 행복이라는 클래스에 대하여 1253개의 샘플을 예측한 것으로 다른 클래스에 비해 과적합된 모습을 보이는 것을 확인할 수 있다. 이에 반해 랜드마크를 추가한 제안 알고리즘의 경우 행복이라는 클래스에 과적합되지 않고 단일 네트워크에 비하여 화남 34개, 중립 30개, 놀람 8개, 역겨움 15개의 샘플에 대하여 올바른 예측을 할 수 있게 되었고, 상대적으로 적은 샘플을 가지는 클래스에 대하여 강인한 모습을 보임을 확인할 수 있다.

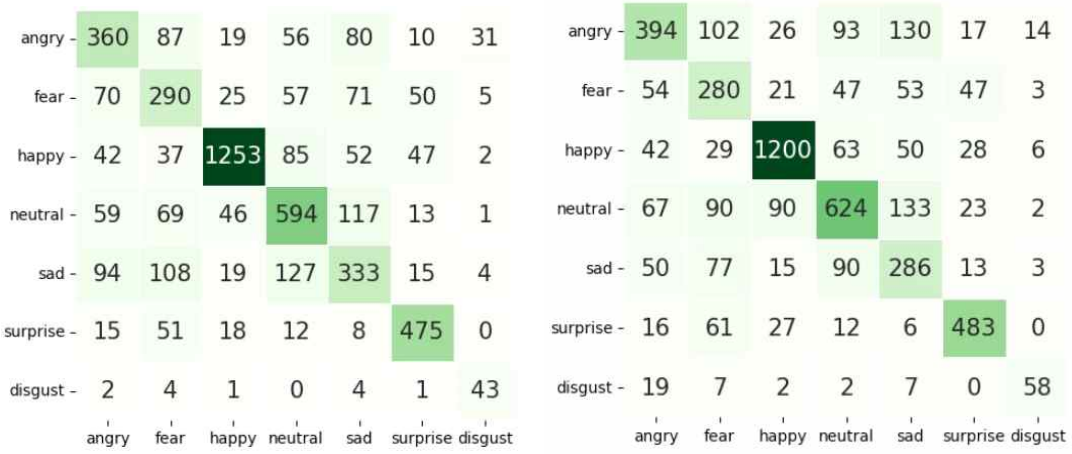

(a) (b)

[그림5-7] VGG 네트워크 오차행렬 비교
(a) VGG 단일 네트워크 오차행렬
(b) 제안 알고리즘 오차행렬

VGG네트워크와 제안 알고리즘의 얼굴 이미지에 대한 감정 클래스에 대한 F1점수는 [표5-5]와 같다. 샘플이 개수가 많은 행복함에 대한 F1 점수는 줄고, 상대적으로 데이터 샘플이 적은 화남, 역겨움, 놀람 클래스에 대하여 약 0.03, 0.05, 0.01점 오른 것을 확인할 수 있다.

[표5-5] VGG 네트워크 F1 점수 비교

	VGG 네트워크	제안 알고리즘
화남	0.5457	0.5712
두려움	0.5094	0.4982
행복함	0.8360	0.8127
중립	0.6206	0.6704
슬픔	0.4687	0.3872
놀라움	0.8159	0.8322
역겨움	0.6622	0.7104

[그림5-8]를 통해 Inception 네트워크에 대하여 랜드마크 추가에 따른 비교한 오차행렬을 확인할 수 있다. 단일 네트워크의 경우 다른 클래스에 비하여 상대적으로 적은 샘플의 수를 가지는 중립, 슬픔, 역겨움이라는 클래스의 샘플에 대하여 정확히 예측하지 못하는 것을 확인할 수 있다. 랜드마크를 추가함으로써 단일 네트워크에 비하여 두려움 77개, 행복함 49개, 중립 8개, 슬픔 8개, 놀람 18개, 역겨움 7개의 샘플을 더 올바르게 예측할 수 있음을 확인할 수 있다.

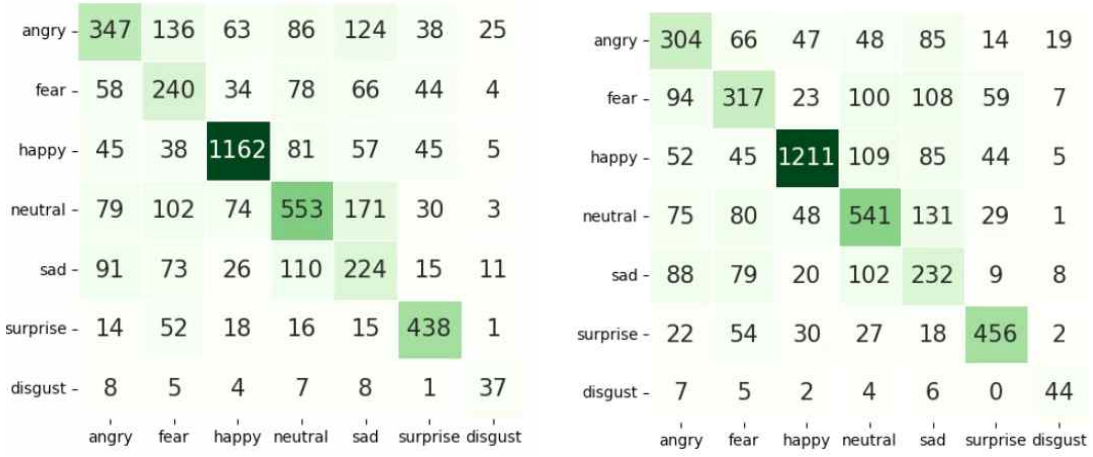

(a) (b)

[그림5-8] Inception 네트워크 오차행렬 비교
(a) Inception 단일 네트워크 오차행렬
(b) 제안 알고리즘 오차행렬

Inception 네트워크와 제안 알고리즘의 얼굴 이미지에 대한 감정 클래스에 대한 F1점수는 [표5-6]와 같다. 놀람 클래스를 제외한 모든 클래스에 대하여 F1 점수가 상승함을 확인할 수 있다.

[표5-6] Inception 네트워크 F1 점수 비교

	Inception 네트워크	제안 알고리즘
화남	0.4752	0.4963
두려움	0.4102	0.4682
행복함	0.8258	0.8260
중립	0.5692	0.5893
슬픔	0.3687	0.3857
놀라움	0.7519	0.7475
역겨움	0.4302	0.5714

본 논문의 연구는 FER2013 데이터셋에 대하여 기하학적 특징인 얼굴 이미지 속 랜드마크를 추가하여 단일 네트워크보다 성능이 향상됨을 보였다. FER2013 데이터셋에 대한 다양한 연구에서는 모델의 성능을 개선하기 위하여 CNN 네트워크의 하이퍼파라미터를 튜닝하고, U-Net 분할 레이어를 통한 성능을 개선하고 있다. 이러한 연구들의 정확도는 [표5-7]에서 확인할 수 있다.

[표5-7] FER2013 데이터셋에 대한 모델 정확도 비교

네트워크 구성	정확도
VGG+MLP(제안)	69.02%
Inception+MLP(제안)	69.31%
VGG[14]	72.7%
Inception[14]	71.6%
Resnet[14]	72.4%
VGG[16]	75.97%

본 논문은 기존의 단일 네트워크를 수정하지 않고, 새로운 MLP 네트워크를 기존 단일 네트워크에 통합하여 새로운 통합 네트워크를 구축함으로써 분류 성능을 향상시켰다. [14,16]와 같이 CNN 네트워크에 대해 튜닝, 하이퍼 파라미터 조절 및 최신 기술을 적용시킴으로써 우리가 제안하는 알고리즘의 성능을 더욱 높일 수 있을 것이라 생각한다.

6. 결론

본 연구에서는 얼굴 감정 분석을 위해 기존의 CNN기반 네트워크 모델에 랜드마크 정보를 통합하여 새로운 얼굴 감정 분석 모델을 구축하였다. 우리는 얼굴의 중요한 랜드마크인 눈, 코, 입과 더불어 주변의 중요한 특징점까지 정교하게 추출하고, 이러한 정보를 이미지 계층과 함께 결합하여 얼굴 감정 분석에 유용한 고유한 특징을 얻었다. 이 추가 정보는 얼굴 표현을 보다 일반화되게 만들어, 다양한 얼굴 유형 및 표정에 대한 모델의 성능을 향상시켰다.

본 연구에서 구축한 모델은 다양한 실험 환경에서 평가되었으며, 이전의 얼굴 감정 분석 모델보다 더 감정을 정확하게 분석함으로써 일반화 능력이 향상됨을 보였다. 이는 현실 세계에서 다양한 상황에서 효과적으로 적용될 수 있음을 말한다. 또한, 랜드마크 정보의 통합으로 얼굴 표정을 민감하게 감지하여 세부적인 감정 차이를 더욱 정확하게 파악할 수 있었다. 이는 각 감정 클래스 간의 성능 격차를 줄여 다양한 감정 상태를 더 균형있게 인식할 수 있음을 의미한다.

우리의 연구는 얼굴 감정 분석 분야에서 랜드마크 정보 통합의 중요성을 입증하였으나, 더 많은 탐구와 개선이 필요하다. 다양한 인종, 연령 및 성별을 대표하는 다양한 데이터를 수집하여 모델의 일반화 성능을 더욱 개선하고, 현실 세계의 다양한 상황에서의 적용 가능성을 보다 강화해야 할 것이다. 또한, 랜드마크 정보 외에도 음성 및 텍스트 데이터와 같은 다중 모달 데이터를 통합함으로써, 다양한 감정을 보다 풍부하게 인식할 수 있도록 모델을 확장할 필요가 있다.

얼굴 감정 분석 분야에서 랜드마크 정보를 통합하여 성능 향상을 입증하였으나, 랜드마크 검출의 정확성에 따라 모델의 성능이 크게 영향을 받을 수 있음을 인지하고 향후 다양한 환경에서도 얼굴 특징을 정확하게 추출하기 위해 연구해야 할 것이다.

참고문헌

[1] D'Mello, S., & Graesser, A. "Dynamics of affective states during complex learning. Learning and Instruction, 22(2), 145-157." 2012

[2] Picard, R. W. "Affective computing. MIT press." 1997

[3] Lee, K., Lee, S., Lee, K., Shin, Y., & Kim, J. "Deep facial expression recognition: A survey. Sensors, 19(3), 537." 2019

[4] Ekman, P. J. "An argument for basic emotions. Cognition & Emotion, 6(3-4), 169-200" 1992

[5] Emily Davis, Michael Wilson "A Survey of Facial Emotion Recognition: Recent Advances and Challenges" 2019

[6] Al-Talabani, Abdul Rahman Saleh and Mohammed, Thajeel I. and Ebrahim, Ahmed Hashim and Rashid, Rasber D."Facial Expression Recognition using Histogram of Oriented Gradients and Hidden Markov Models" 2019

[7] Timo Ahonen, Abdenour Hadid, and Matti Pietikäinen "Facial Expression Recognition using Local Binary Patterns" 2006

[8] Vishal S. Gaikwad, Vishal B. Rathi, and Rajesh H. Kulkarni "Facial Expression Recognition Using Principal Component Analysis: A Review" 2015

[9] Brais Martínez, Óscar Garnica, Iván Maksymets, Carlos Cernuda, Xavier García, Carmen García, Noelia Barreira, Roberto Barros, Tadas Baltrušaitis, and Maja Pantic, "Multimodal Emotion Recognition in the Wild Challenge" 2017

[10] Sarah Brown, David Lee "Facial Landmark Detection and Its Applications in Emotion Analysis: A Comprehensive Review" 2018

[11] Ren, S., Cao, X., Wei, Y., & Sun, J. "Face alignment at 3000 fps via regressing local binary features. In Proceedings of the IEEE conference on computer vision and pattern recognition" CVPR 2014

[12] Jennifer White, Robert Adams "Local Feature-Based Approaches for Facial Emotion Recognition: A Comparative Study" 2016

[13] Fabian Caba Heilbron, Victor Escorcia, Bernard Ghanem, Juan Carlos Niebles “Emotion Recognition in the Wild with Convolutional Neural Networks” 2016

[14] Christopher Pramerdorfer, Martin Kampel, "Facial Expression Recognition using Convolutional Neural Networks: State of the Art" (2016)

[15] Brais Martinez, Michel Valstar, and Xavier Binefa “Going deeper in facial expression recognition using deep neural Facial Expression Recognition using Convolutional Neural Networks: State of the Artnetworks. In Proceedings of the IEEE winter conference on applications of computer vision (WACV) (pp. 1-10)” 2016

[16] S.Vignesh, M.Savithadevi, M.Sridevi & Rajeswari Sridhar, "A novel facial emotion recognition model using segmentation VGG-19 architecture", (2023)

[17] Yaniv Taigman, Ming Yang, Marc'Aurelio Ranzato, Lior Wolf “DeepFace: Closing the Gap to Human-Level Performance in Face Verification” 2014

[18] Michael Wand, Bernd Krieg-Brückner, Fadi Dornaika, and Remi Mégret “Emotion Recognition on the Basis of Multimodal Information” 2009

[19] Xuankai Chang, Shiguang Shan, Xilin Chen, “Facial Expression Recognition with Convolutional Recurrent Neural Networks” 2017

[20] N. Dalal and B. Triggs, "Histograms of oriented gradients for human detection," CVPR 2005.

[21] T.F. Cootes and C.J. Taylor and D.H. Cooper and J. Graham "Active shape models - their training and application". Computer Vision and Image Understanding (61): 38–59. 1995

[22] T. F. Cootes, G. J. Edwards, and C. J. Taylor, “Active Appearance Model,” IEEE Trans. PAMI, Vol.23, No.6, pp.681-685, 2001.

[23] M Iqtait, F S Mohamad and M Mamat, “Feature extraction for face recognition via Active Shape Model (ASM) and Active Appearance Model (AAM)” IOP Conference Series Materials Science and Engineering 332 April 2018

[24] G Lopez Lillo “Facial Landmark Detection using Active Shape Models” 2014

[25] Karen Simonyan, Andrew Zisserman “VERY DEEP CONVOLUTION NETWORKS FOR LARGE-SCALE IMAGE RECOGNITION”, 4 Sep 2014

[26] Christian Szegedy et al. “Going Deeper with Convolutions” 17 Sep 2014

[27] Christian Szegedy et al. “Rethinking the Inception Architecture for Computer Vision” 2 Dec 2015

[28] Ekman, P., Friesen, W. V.,& Hager, J. C. "Facial Action Coding System. Manual and Investigator’s Guide" (2002).

[29] Ruicong Zhi, Mengyi Liu & Dezheng Zhang. "A comprehensive survey on automatic facial action unit analysis" (2020).

[30] Dongwoon Choi, Duk-Yeon Lee, and Dong-Wook Lee, "Development of FACS-based Android Head for Emotional Expressions". (2020)